4팀 11/11 발표 대본

회색 상자 = 그대로 읽어도 되는 말. "가리킬 곳" = 화면에서 짚을 부분. "질문 나오면" = 예상 질문과 짧은 답. 전체 약 12분. 숫자는 모두 2011~2021 검증 구간 기준.

---

01 표지

> 4팀입니다. 지난번 계획을 이번 주에 실제 데이터로 돌려 봤습니다. 앞부분은 정형 변수와 수급 가설 판정 결과, 뒷부분은 뉴스 데이터 진행 상황입니다.

---

02 이번 주에 확인한 것

> 세 줄로 먼저 말씀드리겠습니다. 변수를 단계별로 더할 때마다 IC가 0.051에서 0.092까지 올랐습니다. H1, 개인이 사면 약하다는 가설은 반대로 나왔습니다. H2 외국인은 어느 쪽으로도 뚜렷하지 않았습니다. 뉴스는 약 400개 파일을 모았고 분류 규칙을 시험하는 중입니다.

가리킬 곳: 숫자 세 줄만. 여기서 설명을 길게 하지 않는다.

---

03 결과를 보기 전에 기준부터

> 지난번 결론을 정해 두지 말라고 하셔서, 숫자를 보기 전에 기준을 먼저 정했습니다. 두 가지를 따로 봅니다. 쓸모는 이 변수를 넣으면 예측이 나아지는지이고, XGBoost로 단계마다 IC가 오르는지, 11년 중 6년 이상 오르는지로 판단합니다. 방향은 우리가 세운 가설의 부호가 맞는지이고, Fama-MacBeth 계수의 t값이 2를 넘는지로 봅니다. XGBoost는 나무 모델이라 플러스인지 마이너스인지 알려 주지 않아서 둘을 나눴습니다.

핵심 한 문장: "예측에 쓸모 있는지와 가설이 맞는지는 다른 질문이다."

> **질문 나오면** "XGBoost IC에도 t값을 쓰나?" → IC 자체는 기준선만으로 t가 6이라 의미가 없고, 단계별 증가분에 t를 계산해 참고로 적었습니다. 판정은 평균 상승과 이긴 해 수로 합니다.

---

04 데이터를 열어 보니

> 그래프는 매달 가치 변수, 즉 1/PBR을 쓸 수 있는 종목 비율입니다. 2002년 4월 전에는 PBR 자료가 아예 없고, 2008년 8월부터 11월까지 네 달이 통째로 비어 있습니다. 금융위기 기간입니다. 둘 다 2010년 이전이라 첫 학습에만 영향을 주고, 오른쪽 음영인 검증 구간에서는 빈칸이 0.9%입니다. 순매수는 예원 님이 붙인 값을 다시 계산해 봤는데 오차가 없었습니다.

가리킬 곳: 선이 0으로 떨어지는 두 곳 → 오른쪽 음영.

> **질문 나오면** "빈칸은 어떻게?" → 0으로 채우면 가장 싼 주식이라는 뜻이 돼서, 중간값 0.5를 넣고 빈칸이라는 표시 열을 따로 넣었습니다.

05 결과를 흔들 수 있는 곳

> 결과를 왜곡할 수 있는 곳은 따로 확인했습니다. 예를 들어 상장폐지되는 회사는 마지막 달에 크게 떨어지는데, 그 수익률이 데이터에 없습니다. 개인이 그런 종목을 많이 샀다면 개인 쪽이 좋아 보이는 착시가 생길 수 있어서, 빠진 수익률을 마이너스 30%, 마이너스 100%로 채워 다시 돌렸고 결론은 같았습니다. 한 달에 100% 넘게 오른 칸도 460건 있었는데, 지우지 않고 순위로 바꿔서 영향을 줄였습니다.

가리킬 곳: 표 첫 줄(상장폐지)만 예로 들고 나머지는 "같은 방식으로 확인했다".

> **질문 나오면** "외국인 0은?" → 2000년대 초 소형주는 외국인이 아예 거래하지 않아 0이 많았습니다. 자료가 없는 게 아니라 거래가 없던 것이라 0으로 뒀고, 검증 구간에서는 2.8%입니다(92,691줄 중 2,552줄).

06 해마다 1년씩 쌓아서 학습

> 2001년부터 2010년까지로 학습하고 2011년을 맞힙니다. 그다음 2011년을 더해 다시 학습하고 2012년을 맞힙니다. 2021년까지 11번 반복합니다. 이렇게 한 이유는 실제 투자자도 그 시점까지 나온 자료로만 판단하기 때문입니다. 학습과 검증 기간이 너무 멀다는 지난번 말씀도 반영했습니다. 입력은 t월 말까지 아는 정보, 정답은 다음 달 수익률 순위이고, 모델 설정은 결과를 보고 바꾸지 않았습니다.

가리킬 곳: 초록 막대가 한 칸씩 길어지는 것.

> **질문 나오면** "12월 줄은?" → Y년을 예측할 때 Y−1년 11월 줄까지만 씁니다. 12월 줄의 정답이 Y년 1월 수익률이라 그 시점엔 모르기 때문입니다.

07 묶음을 더할 때마다 IC 상승

> IC는 우리가 매긴 순위와 실제 다음 달 수익률 순위가 얼마나 비슷한지입니다. 기준선 세 개로 0.051, 단기 반전과 모멘텀을 더하면 0.077, 고유변동성과 주식 발행을 더하면 0.088, 순매수까지 0.092입니다. 막대 안 숫자는 직전보다 오른 폭과 11년 중 이긴 해 수입니다. 네 단계 모두 통과했습니다. 혹시 코드에서 미래 정보가 새는지 보려고 정답을 무작위로 섞어 학습해 봤는데 IC가 0에 가까웠습니다.

가리킬 곳: 통제 막대(+0.026, 가장 큰 상승).

> **질문 나오면** "0.09면 높은 건가?" → 월별 종목 순위 예측에서는 0.05만 넘어도 쓸 만한 수준으로 봅니다. 다만 시총 상위 100 안에서만 재면 0.023으로 낮아서, 예측력은 대부분 중소형주에서 나옵니다. 보고서에 둘 다 적겠습니다.

08 하나씩 넣어 보면

> 묶음 안에서 누가 기여했는지 보려고 하나씩 넣어 봤습니다. 주황이 탈락입니다. 규모는 베타 다음에 혼자 넣으면 조금 떨어지는데, 기준선은 판정에서 빼기로 했고 다른 변수와 같이 넣으면 방향이 가장 뚜렷해서 유지합니다. 주식 발행은 고유변동성 다음에 넣으면 IC가 그대로입니다. 주식을 많이 찍는 회사가 대체로 변동성도 커서, 고유변동성이 이미 같은 정보를 담고 있습니다. 그래서 빼자는 쪽입니다.

가리킬 곳: 맨 오른쪽 주황(주식 발행 −0.000) → 그 왼쪽 고유변동성(11/11).

> **질문 나오면** "주식 발행이 틀린 변수인가?" → 아닙니다. 2002~2021 전체로 보면 방향은 맞습니다(t −3.2). 다만 고유변동성과 겹쳐 새로 보태는 게 없습니다.

---

09 해마다 나눠 보면

> 평균만 보면 몇 해의 큰 성과가 섞여 있을 수 있어서 연도별로 봤습니다. 점 하나가 그해 평균 IC입니다. 진한 초록이 수급까지 넣은 모델, 회색이 기준선인데 대부분의 해에서 위에 있습니다. 2020년은 코로나 급락과 반등이 있던 해라 네 선이 거의 겹칩니다.

가리킬 곳: 회색과 진한 초록 사이 간격 → 2020년.

---

10 개인이 많이 산 종목이 더 올랐다 (H1·H2)

> 매달 종목을 순매수 비율로 다섯 그룹으로 나눴습니다. 왼쪽이 가장 많이 판 20%, 오른쪽이 가장 많이 산 20%이고 막대는 그 그룹의 다음 달 평균 수익률입니다. 양 끝을 비교하면 차이가 가장 잘 보입니다. 개인은 많이 판 그룹이 0.58%, 많이 산 그룹이 1.28%입니다. 저희는 내려가는 모양을 예상했는데 반대로 올라갑니다. 외국인은 많이 산 그룹이 오히려 낮지만 t가 −1.5라 판단을 보류합니다.

가리킬 곳: 왼쪽 그래프 양 끝 주황 막대 두 개.

> **질문 나오면** "왜 20%씩?" → 한 그룹에 140종목 정도라 평균이 안정적이고, 효과가 있으면 양 끝에서 가장 크게 벌어지기 때문입니다. 학계에서 쓰는 표준 방식입니다.

> **질문 나오면** "t값이 뭔지 설명해 보라" → 131개월 동안의 차이 평균을, 그 차이가 달마다 흔들리는 정도로 나눈 값입니다. 0.70을 오차 0.23으로 나누면 3.1이고, 2를 넘으면 우연으로 보기 어렵습니다.

11 다른 변수를 함께 넣어도

> 9개 변수를 한꺼번에 넣고 매달 회귀를 돌려 계수의 t값을 본 것입니다. 초록은 예상대로, 주황은 예상과 반대, 회색은 판단 보류입니다. 규모는 예상대로 강하게 마이너스이고, 개인 순매수는 예상과 반대로 +3.1입니다. 개인은 그달 떨어진 종목을 사는 편이라 그냥 반등한 것 아니냐는 의문이 들 수 있는데, 단기 반전을 같이 넣어도 효과가 남았습니다.

가리킬 곳: 주황 막대(개인 +3.1) → 점선 2.

> **질문 나오면** "가치·반전은 왜 회색인데 XGBoost에선 통과?" → 겹치는 변수를 한꺼번에 넣으면 t가 나뉘어 작아지고, 회귀는 직선만 보기 때문입니다. 예를 들어 베타는 다섯 그룹 중 가장 높은 그룹만 뚝 떨어지는 모양이라 직선으로는 잘 안 잡힙니다.

---

12 데이터를 바꿔 넣어도

> 결과가 데이터 처리 때문이 아닌지 여러 가지로 바꿔 봤습니다. t가 모두 2.8에서 3.4 사이였고, 연도별로도 11년 중 10년이 같은 방향입니다. 계획서에 반대 가능성으로 적어 둔 유동성 공급 쪽입니다. 외국인이나 기관이 회사 사정과 상관없이 급하게 대량으로 팔면 가격이 지나치게 눌리는데, 개인이 그 물량을 받아 주고 다음 달 가격이 돌아오면서 보상을 받는다는 설명입니다. 미국 자료에서도 비슷한 결과가 있습니다.

> **질문 나오면** "다 팔았는데 어떻게 오르나?" → 판 이유가 회사가 나빠서가 아니라 급해서라면, 가격이 가치보다 더 내려갔다가 매도가 끝나면 돌아옵니다. 그 되돌림을 받아 준 쪽이 가져가는 겁니다. 아직은 해석 후보입니다.

---

13 9개 중 8개를 남긴다

> 정리하면 주식 발행만 빼자는 제안입니다. 개인 순매수는 가설과 반대지만 11년 모두 예측을 개선해서 모델에 남깁니다. H1은 지지되지 않았고 반대 방향이 유의했다고 그대로 적겠습니다. 결과를 보고 가설을 고쳐 쓰지는 않습니다.

> **질문 나오면** "가설을 수정하나?" → 원래 가설은 그대로 두고 결과를 기록합니다. 새 설명은 사후 해석으로 표시하고, 마지막 test 구간에서 같은 방향이 나오는지 한 번 더 확인합니다.

---

14 뉴스 (구분)

> 여기서부터 뉴스입니다. 아직 판정 결과는 없고, 데이터를 어떻게 모았고 앞으로 어떤 순서로 처리할지 말씀드리겠습니다.

15 상위 100개 회사, 경제지 5곳

> 대상은 매년 직전 연도 말 시가총액 상위 100개 회사이고, 21년 동안 들어온 회사를 합치면 242개입니다. 오늘 기준으로 고르면 미래 정보가 되기 때문에 직전 연도 말 기준입니다. 처음엔 200개를 생각했는데 파일럿에서 상위 100이 기사의 85% 정도라 100개로 줄였습니다. 뉴스토어는 승인이 2주 걸리고 한경·매경 자료가 없어서 빅카인즈에서 직접 받았습니다. 지금 약 400개 파일이 모였고 11월 22일까지 마칩니다.

16 모델은 네 번째 단계

> 감성 모델을 바로 돌리지 않는 이유를 실제로 확인했습니다. KT&G 2021년 파일을 열어 보니 40% 정도가 다른 회사 상품이나 배당주 칼럼처럼 KT&G와 관계없는 기사였습니다. 빅카인즈가 본문까지 검색하기 때문입니다. 그대로 넣으면 다른 회사 기사의 논조가 KT&G 점수로 들어갑니다. 그래서 제목에 회사 이름이 있는 기사만 남기고, 유형 분류를 사람 정답과 비교해 통과한 뒤에 모델을 돌립니다. 단계마다 기준을 못 넘으면 규칙을 고쳐 다시 합니다.

가리킬 곳: 4번 카드(주황) — "모델은 여기".

17 분류 규칙 시험 100건

> 회사 하나, 1년치에서 100건을 뽑아 팀 분류 지시문대로 나눠 봤습니다. 키워드만으로 나눈 결과와 같은 건 35건뿐이었습니다. 그래서 키워드 규칙을 그대로 쓰지 않고 사람 정답과 80% 넘게 맞는 방식으로 정하려 합니다. 가장 먼저 정할 건 사회공헌이나 수상 기사를 버릴지 화제형으로 볼지입니다. 지난번 예로 드신 유상증자 논란 같은 기사는 겹친다고 표시하고 사람이 판단합니다.

질문 나오면 "다음 시험은?" → 여러 회사·연도에서 새 100건을 뽑아 두 사람이 서로 보지 않고 정답을 달고, 분류 결과와 비교합니다. 같은 100건을 다시 쓰면 점수가 부풀려져서 매번 새로 뽑습니다.

18 H3, H4 판정 계획

> H3는 지금까지와 같이 수급까지 넣은 모델에 기사 논조를 하나 더 쌓아 IC를 보고, 방향은 Fama-MacBeth로 봅니다. H4는 비교표입니다. 오늘 개인이 산 종목이 원래 다음 달에 더 오른다는 결과가 나왔기 때문에, 호재 종목에서의 차이에서 기사 없는 종목의 같은 차이를 빼서 호재일 때만 달라지는 부분을 봅니다. 기사가 수집되지 않은 회사를 기사 없음으로 착각하지 않도록, 그해 기사가 실제로 모인 종목만 평가합니다.

19 여쭙고 싶은 것

> 결과를 보고 생긴 질문 네 가지입니다. 개인 순매수 결과를 유동성 공급으로 해석해도 되는지, XGBoost 증가분의 t값을 보조 근거로 써도 되는지, 주식 발행을 빼도 되는지, 그리고 사회공헌·홍보 기사를 어떻게 다룰지입니다. 첫 번째와 네 번째가 다음 주 작업에 바로 필요합니다.

20 일정

> 11월 16일까지 분류 시험 2차, 22일 수집 마감, 25일에 뉴스 판정을 마치고 설정을 고정합니다. test 기간은 그 뒤에 한 번만 돌립니다. 감사합니다.

발표 전 체크

① 표지·뉴스 구분·질문 장의 그림 자리 3곳에 그림을 넣었는지 ② 15번 수집 현황 숫자를 담당자에게 최신으로 확인 ③ 링크 공유 설정 ④ t값, IC, 5분위는 각각 한 문장으로 말할 수 있게 연습 (10번 장의 답 참고)