# 4팀 11/11 발표 피드백 정리와 다음 발표 준비

출처: 11/11 수업 녹음 2개(자동 받아쓰기). 받아쓰기가 많이 깨져 있어 문맥으로 복원했고, 확신이 낮은 곳은 **(추정)**으로 표시했다. 녹취 끝부분의 "사이즈 부호를 반대로 적용…" 대목은 다른 팀 발표로 보여 제외했다.

**한 쪽 요약: 다음 발표까지 할 일 7가지**

1. **잘한 점 유지:** 모델 전에 데이터를 먼저 찍어 본 것(9개 변수 5분위 그림)을 좋게 보셨다. 이 방식을 기간별로도 해 본다.
2. **뉴스도 먼저 찍어 보기:** 모델에 넣기 전에 "기사 논조가 좋으면 다음 달 수익률이 높은가"를 같은 방식의 그림으로 보여 준다.
3. **뉴스를 어떤 단위로 쓸지 정하기:** 회사(종목)별 신호인지, 시장·업종 전체의 흐름인지.
4. **LLM 사용 계획과 비용:** 전부 유료 API로 분류하면 수십만 원이 들 수 있다. 오픈소스 LLM을 GPU 인스턴스에서 돌리는 대안과 정확도를 비교한다.
5. **계산 자원과 시간 먼저 정하기:** 어디서(클라우드 인스턴스/로컬) 돌릴지, 얼마나 걸릴지 정하고 서둘러 시작한다. 자동 수집(크롤링)은 법·차단 문제를 조심한다.
6. **학습 기간을 줄여 보기:** 해마다 쌓는 방식은 괜찮다. 다만 "데이터를 다 쓰는 게 꼭 좋은가"를 보려고 오래된 앞쪽을 잘라내는 방식(롤링)도 함께 돌려 비교한다.
7. **SHAP으로 XGBoost의 방향 보기:** 트리 모델은 +/−를 직접 말해 주지 않지만, SHAP 값을 찍으면 대략 볼 수 있다. 써 보라고 하셨다.

## 1. 피드백 항목별 상세

### 칭찬 F1. 일단 찍어 본 것이 좋았다

> "여기는 오히려 좀 낫다 싶은 생각이 드는 게, 일단 하고 보자 해서 쭉 찍어 본 다음에 된 거잖아요. 그 사이가 되게 좋을 것 같아요. 여러분들도 한번 찍어 보라는 게… 아까 그 9개짜리 표 있는 거, 이런 식으로."

**뜻:** 변수마다 5분위로 나눠 다음 달 수익률을 본 그림(9개 칸짜리 그림 A)처럼, 모델 전에 데이터로 방향을 먼저 확인한 과정을 좋게 평가하셨다.

**준비:** 이 방식을 기본 절차로 유지하고, 다음 발표에서도 "찍어 본 그림 → 모델 결과" 순서로 보여 준다.

### 보완 F2. 연도별로, 그룹 수를 바꿔서도 달라질 수 있다

> "이게 사실 연도별로 나눠서 또 다를 수도 있고, 그다음에 저 그룹은 10개가 조금 다를 수가 있는데(추정: 10분위로 나누면 달라질 수 있는데), 일단은 이 변수를 할까 말까는 대충 저렇게 보여야… 2번 변수(규모)는 내려가면 내려갈수록 높다는 게 보일 것 같으니까."
> "물론 저게 무조건인지는 모르죠. 모델에 반영했을 때 안 오를 수도 있고, 우리가 거르지 못한 어떤 필터링이 있어서 안 맞을 수도 있는데, 적어도 확인할 수 있는 근거는 있어야."

**뜻:** 그림 한 장(11년 평균)만으로는 부족하다. ① 기간을 나눠도 같은 모양인지 ② 5분위 대신 10분위로 나눠도 같은지 확인하라. 또 미리 보기에서 좋아 보여도 모델에서는 효과가 없을 수 있으니, 둘을 같이 보여 주라.

**준비:** 9개 변수 그림을 (가) 2011–2015 / 2016–2021, (나) 10분위로 다시 그린다. 방향이 바뀌는 변수는 표시한다. "미리 보기 → 모델 판정" 대응표를 만든다(예: 규모는 미리 보기 강함 / XGBoost 단독 추가는 약함 / FM 강함).

### 보완 F3. 뉴스도 먼저 찍어 보라

> "마찬가지로 뉴스도 그런 게 있는지 한번 찍어는 봐야 될 것 같고요."

**준비:** 모델에 넣기 전에 ① 화제형 기사 논조 5분위 → 다음 달 수익률 ② 기사 있음/없음 그룹의 다음 달 수익률 ③ 기사 수 많음/적음 그룹을 그린다. 분석 코드(`step9_news_h3h4.py`)는 준비돼 있고, 종목×월 집계 파일만 있으면 된다.

### 보완 F4. 뉴스를 어떤 단위로 쓰는가

> "여러분들이 뉴스를 어떻게 쓰는지 몰라서… 뉴스라는 게 회사 단위냐, 종목 단위냐, 아니면 전체에 대한 그 계열의 흐름이 있냐, 어떤 걸 활용하시냐에 따라 다를 것 같은데."
> (우리 답) "리스트에 이 회사 이름이 있으면 이 회사 관련해서 모은 다음에… 전체를 넣어 놓은 다음에 기사를 분류해서…"

**뜻:** 뉴스 변수가 ① 개별 회사(종목)의 소식인지 ② 시장·업종 전체의 분위기인지 발표에서 분명하지 않았다.

**준비 (우리 답 정리):** 우리는 **종목 단위**다. 제목에 회사 이름이 있는 기사만 그 회사에 붙이고, 회사×월로 화제형 기사 논조를 평균 낸다. 시장 전체 분위기는 매달 모든 종목에 똑같이 들어가 순위(IC)에는 영향을 주지 않으므로 쓰지 않는다. 이걸 흐름도 한 장(기사 → 회사 매칭 → 유형 분류 → 감성 점수 → 회사×월 → H3/H4)으로 보여 준다.

## 보완 F5. 기사 분류와 LLM 비용

> "기사 종류 분류, 이 분류라는 건 어떤 거예요?" (우리 답) "공시형, 화제형, 논란형…"
> "써도 상관은 없겠는데, API가 만만치 않을 것 같은데… (기사가 수천 개 단위)라고 하면 다 필터링하면, 저 비슷한 돈은 아니더라도 한 몇십만 원 나올 것 같은데 괜찮아요? … LLM 어떻게 쓰려고 했어요?" (우리) "아직 안 써 봤고…" "그거를 정해 놔야 될 것 같은데."

**뜻:** 분류 자체는 괜찮다. 하지만 모든 기사를 유료 LLM API로 분류하면 비용이 크니, 어떻게 쓸지 정하라.

**준비:**

| 할 것 | 내용 |
|---|---|
| 분류 대상 기사 수 확정 | 정리 시험에서 2,641건 → 980건(약 37%)이 남았다. 전체 파일에 같은 비율을 적용해 분류할 기사 수를 추정한다. |
| 비용 계산식 | 기사 수 × (제목+본문 200자 ≈ 입력 토큰 + 출력 약 30토큰) × 모델 단가. 단가는 쓸 모델 기준으로 넣는다. |
| 비용 줄이는 순서 | ① 제목 매칭으로 먼저 거른다(무관 기사 약 40% 제거) ② 키워드로 확실한 것(예: "특징주", "압수수색")은 바로 분류 ③ 애매한 것만 LLM에 보낸다. |

## 보완 F6. 오픈소스 LLM + GPU 인스턴스 대안

> "예를 들면 (오픈소스 LLM) 같은 오픈 소스 해 놓고, GPU 인스턴스 (빌려서) 그냥 계속 돌려 놓고 하면, 인퍼런스 타임 하면 그것보다 좀 싸게 할 수 있을 것 같고요. 얼마나 정확한지 모르겠지만."

**뜻:** 유료 API 대신 공개된 LLM(예: Llama·Qwen·EXAONE 계열, 녹취에선 "PM"으로 들림)을 GPU 서버에서 직접 돌리면 추론 비용이 더 싸다. 단, 정확도는 확인해야 한다.

**준비:** 같은 100건(사람 2명이 정답을 단 것)으로 ① 키워드 규칙 ② 유료 LLM ③ 오픈소스 LLM(Colab/GPU 인스턴스)의 일치율과 처리 시간을 비교표로 만든다. 80% 이상이면서 싼 쪽을 고른다.

### 보완 F7. 계산 자원과 시간을 먼저 정하고 서둘러라

> "그건 스크립트야 바로 짜면 될 것 같은데… 돌리려면 시간이 꽤 있을 건데 어떻게 할지… 그래서 일단 대충 먼저 정해 놔야 돌리는 거, 시간 꽤 걸릴 것 같거든요." "여기는 인스턴스 같은 걸 쓰고 있어요, 아니면 로컬에서 하고 있어요?" "계속 감시해 놓을 거 아니면… 좀 서둘러야 될 것 같아요." "일단 최대한 빨리 뉴스를 쓸 거면, 받아서… 이거 어떻게 써야 되는지랑 리소스 괜찮은지랑 대충 시간을 봐야."

**준비:**

| 결정할 것 | 제안 |
|---|---|
| 어디서 돌리나 | 감성 점수(KR-FinBert-SC)는 Colab T4 GPU로 충분하다. 노트북은 만들어 두었고, 끊겨도 이어서 돌아가게 캐시를 둔다. LLM 분류를 오픈소스로 하면 GPU 인스턴스가 필요할 수 있다. |
| 얼마나 걸리나 | 파일 3~5개로 먼저 돌려 "파일 1개당 시간"을 재고, 전체 시간을 추정해 발표에 적는다. |
| 언제 시작하나 | 수집이 끝난 담당 파일부터 바로 돌린다(전체 마감을 기다리지 않음). |

### 주의 F8. 자동 수집(크롤링)의 법적 문제와 차단

> (발표 중 질의, 추정) "합법과 불법의 경계… 크롤링으로 공유할 수 있는 걸 스케줄 만들어 놓고 (제한을) 뛰어넘게 한다는 거죠?" "차단당할락 말락 하다가 분명히 걸렸습니다." "그 방법 이전에 다른 방식으로 조회하는 걸 시도하다가 통째로 (막혔고)… 집에 가서 다른 와이파이로 해도 막히더라고요." "어쨌든 법은 있다고 하니, 글쎄요."

**뜻 (추정):** 자동으로 기사를 긁는 방법을 시도했다가 접속이 차단된 사례와, 그런 방식이 법적으로 애매하다는 이야기다. 교수님은 "관련 법은 있다"며 조심하라는 뉘앙스였다.

**준비:** 우리는 빅카인즈 화면에서 사람이 직접 받는 방식만 쓰고, 자동 크롤링은 하지 않는다고 분명히 적는다. 남은 회사도 같은 방식으로 받는다(질문했던 "API 말고 다른 방법"의 답).

### 보완 F9. 누적 학습은 좋다. 학습 기간을 줄여 보는 것도 돌려 보라

> "이게 이제 올랐을 때, 이렇게 누적하는 건 OK인데, 그때 반대쪽에서 이렇게 당길 필요는 없나 싶은 고민이 들었던 것 같아요. 학습을 꼭 다 써야 무조건 좋구나 하는 건 아닐 것 같긴 해서, 그것도 한번 고민해 보면 좋을 것 같네요. … 어딘가 이렇게 줄어드는 거 해 가지고, 조합은 그냥 돌려 놓고 그냥 냅두고 다른 거 하면 되잖아요. 이제 확인만 하면 될 거니까."

**뜻:** 지금은 2001년부터 계속 쌓는 확장 윈도우다. "반대쪽에서 당긴다" = 학습 시작점도 같이 앞으로 당겨서 오래된 해를 버리는 것(롤링 윈도우). 20년 전 시장은 지금과 다를 수 있으니, 최근 몇 년만 학습하는 쪽이 더 나을 수도 있다. 여러 조합을 자동으로 돌려 두고 결과만 확인하라.

**준비:** 같은 단계별 IC를 학습 기간 5년·7년·10년 롤링과 확장(지금)으로 돌려 한 표·한 그림으로 비교한다. 규칙(평균 IC↑ & 6/11년)은 그대로 둔다. 결과를 보고 고르는 게 아니라 "확장이 꼭 나은가"를 보이는 용도라고 밝힌다.

### 보완 F10. 종목마다 뉴스 빈도가 다르다. 메이저만 할 건가

> (첫 녹음) "뉴스의 공통적인 건데, 이게 종목별로 뉴스 빈도가 다 있지만, 흔히 말하는 작은 주는 뉴스가 진짜 안 나오고 커질 때 나오는 것 같아서… 그런 건 그냥 무시하고 메이저만 할 건가도 정해야 될 것 같아서." (둘째 녹음) "그런 거 그냥 무시하고 메이저만 하는 거 아닐까도 정해야."

**뜻:** 작은 회사는 평소 기사가 거의 없다가 주가가 크게 오를 때 기사가 쏟아진다. 그러면 "기사가 있다"는 사실 자체가 이미 오른 종목이라는 신호가 되어 결과가 왜곡될 수 있다. 범위를 대형주(메이저)로 한정할지 정하라.

**준비:** 우리는 이미 매년 직전 연도 말 시총 상위 100만 수집했다(사실상 메이저). 이를 분명히 밝히고, 평가도 그 100개 안에서만 한다. 추가로 기사 수가 직전 달 수익률과 얼마나 같이 움직이는지 그림으로 보여 주고, 기사 수 자체는 변수로 쓰지 않는다.

### 보완 F11. 트리 모델의 방향은 SHAP 값으로 보라

> "트리 부스트(트리 기반 부스팅)는 이게 플러스냐 마이너스냐(포지티브/네거티브)를 모른다는 거, SHAP 밸류 같은 거 찍으면 얼추 볼 수 있거든요. (SHAP)이라고 검색하면 나오니까 그거 한번 써 보세요."

**뜻:** 우리가 "XGBoost는 방향을 알려 주지 않아서 Fama-MacBeth로 따로 본다"고 했는데, SHAP을 쓰면 XGBoost 안에서도 변수가 클 때 예측이 올라가는지 내려가는지 대략 볼 수 있다.

**준비:** 수급까지 넣은 XGBoost 모델로 SHAP summary plot과, 개인 순매수·규모·단기 반전의 dependence plot을 그린다. Fama-MacBeth 방향과 같은지 대조표를 만든다. 팀 저장소 `requirements.txt`에 `shap`이 이미 있고, `06_explain.py`에 자리(`shap_dependence`)도 있다.

## 2. 녹취에서 애매했던 말 해석표

| 받아쓰기 | 해석 | 근거 |
|---|---|---|
| 볼링 | 크롤링 | "스케줄 만들어 놓고", "차단", "다른 와이파이" → 자동 수집 이야기 |
| 뛰어넘게 한다 | 요청 제한을 우회 | 차단당했다는 말과 이어짐 |
| 알랑말랑 | (차단될) 락 말락 | "분명히 걸렸습니다"와 이어짐 |
| 김상에서 보여주는 | 지금 화면(장표)에서 보여 주는 | 발표 화면을 보며 질문 |
| 병류 / 종료 | 분류 / 종류 | "기사 종류 분류"를 묻는 문장 |
| 임지현 / 이상 증상 화제성 논란 | 공시형 / 공시형·화제형·논란형 | 우리 분류 이름 |
| APM | API | 비용("만만치 않을") 이야기 |
| 4천 음악이라고 하면 / 형사로 | (기사가) 수천(만) 건이라면 / 전부 (LLM으로) | "다 필터링하면 몇십만 원" (추정, 숫자 불확실) |
| LM / PM 같은 오픈 소스 | LLM / 오픈소스 LLM (Llama 등) | "오픈 소스 해 놓고 GPU 인스턴스" (모델 이름은 불확실) |
| GP 인스턴스 | GPU 인스턴스(클라우드 GPU 서버) | "계속 돌려 놓고", "인퍼런스" |
| 인퍼런스 타임 | 추론(inference) 시간·비용 | "그것보다 좀 싸게" |
| 9개짜리 표 | 9개 변수 5분위 그림(그림 A) | "쭉 찍어 본", "2번 변수 내려갈수록 높다"(규모) |
| 저 그룹은 10개가 | 10분위로 나누면 | "조금 다를 수가 있는데" (추정) |
| 토하지 못한 필터링 | 거르지(통제하지) 못한 요인 | "걔네들이 안 맞을 수도" |
| 용수 학생들 | 여러분(학생들) | "고민해 보세요" |
| 좌초 방지를 다 쓰고 | (자원·장비를) 다 쓰고 (추정) | "돌리려면 시간이 꽤", "인스턴스냐 로컬이냐"와 이어짐 |
| 감사 이게 해놓을 거 | 계속 감시(모니터링)해 놓을 거 | "아니면 서둘러야" |
| 반대쪽에서 당길 | 학습 시작점도 당기기 = 롤링 윈도우 | "누적하는 건 OK인데", "줄어드는 거" |
| 답주 / 작은 주 | 작은 주식(소형주) | "뉴스 진짜 안 나오고 커질 때 나온다" |
| 트리버스트 / 하드트 네거티브 | 트리 부스트 / 포지티브·네거티브(방향) | "모른다는 거", "찍으면 얼추 볼 수 있다" |
| 샵 밸류 / j JP / 이 벡터 | SHAP value / SHAP(검색어) / (불확실) | "검색하면 나오니까 써 보세요" |

## 3. 다음 발표 준비 계획

| 순서 | 할 일 | 피드백 | 결과물 | 필요한 것 |
|---|---|---|---|---|
| 1 | 롤링(5·7·10년) vs 확장 단계별 IC | F9 | 비교표 + 그림 1장 | 지금 데이터로 가능 |
| 2 | SHAP summary·dependence plot, FM 방향과 대조 | F11 | 그림 2장 + 대조표 | 지금 데이터로 가능 |
| 3 | 9개 변수 그림 기간별·10분위 | F2 | 그림 2장 | 지금 데이터로 가능 |
| 4 | 뉴스 처리 시간 실측(파일 3~5개) | F7 | 시간·자원 표 | 기사 파일 몇 개 |
| 5 | 분류 100건 비교: 키워드 / 유료 LLM / 오픈소스 LLM vs 사람 2명 | F5, F6 | 정확도·비용·시간 표 | 사람 정답 100건 |
| 6 | 뉴스 찍어 보기: 논조 5분위, 기사 유무 | F3, F10 | 그림 2장 | 종목×월 집계 파일 |
| 7 | 뉴스 단위·범위 흐름도, 수집 방식(수동) 명시 | F4, F8, F10 | 슬라이드 1장 | 없음 |

### 다음 발표 슬라이드 구성안

1. 지난 피드백과 우리가 한 것 (이 문서의 표를 한 장으로)
2. 학습 기간을 줄여 보면? 확장 vs 롤링 (F9)
3. XGBoost 안에서 본 방향: SHAP (F11)
4. 기간을 나눠 찍어 보면 (F2)
5. 뉴스는 이렇게 씁니다: 종목 단위 흐름도, 상위 100, 수동 수집 (F4, F8, F10)
6. 뉴스도 먼저 찍어 봤습니다 (F3)
7. 분류 방법 비교와 비용·시간 (F5, F6, F7)
8. H3·H4 결과 또는 일정

1~3번은 지금 있는 데이터로 바로 할 수 있다. 4~6번은 기사 파일(또는 Colab 노트북 실행 결과)이 필요하다.