4팀 뉴스 데이터 가공·검증 로드맵

빅카인즈에서 받은 기사 → H3·H4 판정까지, **어떤 순서로, 무엇을 확인하며** 갈지 정한 문서. 2026-11-10 작성.

> **왜 "일단 모델부터 마구 돌리면" 안 되나?**
> 감성 모델(KR-FinBert-SC)은 기사 한 건에 "긍정·부정" 점수를 매길 뿐이다. 어떤 기사를 넣을지(회사와 관련 있는 기사인가? 공시인가 화제인가?)가 틀리면, 점수가 아무리 정확해도 결과가 쓰레기가 된다. 실제로 KT&G 2021 파일 421건 중 **약 40%가 KT&G와 무관한 기사**였다(본문 검색 때문). 이 상태로 돌리면 "삼성증권 ISA 출시" 기사 점수가 KT&G 논조로 들어간다.
> → 그래서 **모델은 4단계**이고, 그 앞 세 단계를 통과 기준과 함께 먼저 끝낸다. 교수님 피드백 ④ "테스트 → 확인 → 개선 반복", ⑤ "AI에 그냥 맡기면 이상해진다"가 바로 이 얘기다.

전체 흐름 한눈에

#	단계	입력 → 출력	통과 기준(게이트)	누가
0	수집 마감·목록 점검	드라이브 xlsx → 수집 점검표	검색목록 153줄이 모두 파일로 있음	담당 1~4 각자
1	정리	xlsx → 기사 표(중복 제거)	건수 기록, 중복·제외 비율 확인	Colab 노트북 셀 1~2
2	회사 매칭	기사 → (기사, 종목코드)	무작위 50건 눈 확인, 틀린 매칭 5% 미만	노트북 셀 3 + 사람 1명
3	유형 분류	→ 공시형/논란형/화제형/기타	새 100건, 사람 2명 정답과 일치 80% 이상	LLM 또는 규칙 + 사람 2명
4	감성 점수	→ 기사별 s = P(긍정)−P(부정)	뚜렷한 기사 30건에서 방향 맞음	노트북 셀 4 (GPU)
5	월 배정·집계	→ 종목×월 논조, 기사 수	달별 기사 수 그래프에 빈 구간 없음	노트북 셀 5
6	판정	→ H3 단계별 IC·FM, H4 설거지 표	지금(H1·H2)과 같은 규칙	`step9_news_h3h4.py`

단계별 상세

0. 수집 마감과 목록 점검 (마감 11/22)

검색목록 엑셀(`뉴스수집_검색목록_상위100_최종.xlsx`)의 "실제 건수·완료" 칸과 드라이브 파일을 맞춰 본다. 11/10 밤 드라이브 기준 대략 진행: 담당1 33/37, 담당2 38/39, **담당3 15/39**, 담당4 31/40 (파일 이름 순번 기준).

주의: 파일 이름 순번이 검색목록 순번과 어긋난 사례가 있다(담당2 `034_2021` 파일 내용은 KT&G인데 목록 34번은 SK하이닉스 묶음). 그래서 **파일 이름으로 회사를 정하지 않고**, 2단계에서 제목으로 회사를 찾는다.

> 게이트: 153줄 모두 "완료 + 파일 있음". 못 채운 줄은 "미수집"으로 표시 → 6단계에서 그 회사·기간을 분석에서 뺀다(기사 없음으로 착각 금지).

1. 정리

- 열: 뉴스 식별자, 일자, 언론사, 제목, 본문(200자), 분석제외 여부.
- 빅카인즈 "분석제외 여부"가 중복·예외인 기사 삭제 (KT&G 2021: 421 → 404).
- 언론사 5곳만. **뉴스 식별자**가 같은 기사, (제목, 언론사, 일자)가 같은 기사는 하나만 — OR 묶음 검색끼리 같은 기사가 여러 파일에 들어 있기 때문.

> 게이트: 파일별 "읽은 건수 → 남은 건수"를 표로 남긴다. 한 파일에서 20% 넘게 빠지면 그 파일을 열어 이유 확인.

2. 회사 매칭 (가장 중요)

- **제목**에 회사 이름(현재 이름 + 옛 이름)이 있는 기사만 남긴다. 본문만 언급한 기사는 버린다.
- 짧은 영문 이름 보호: "KT"로 "KT&G", "KTB"를 잡지 않는다. 긴 이름 먼저("SK하이닉스"가 "SK"보다 먼저).
- 두 회사에 같은 이름이 걸리면(모호) 그 이름은 쓰지 않는다. 제목에 회사가 둘이면 두 회사 모두에 붙인다.
- 옛 이름 표는 추정이므로, 매칭 결과에서 회사별 기사 수가 0이거나 갑자기 튀는 해를 확인한다.

> 게이트: 무작위 50건을 사람이 보고 "이 기사가 정말 이 회사 기사인가" 체크 → 틀린 것 5% 미만(3건 이하). 넘으면 이름 표를 고치고 다시.

3. 유형 분류 (교수님 피드백 ①②⑤)

우선순위: 광고 → 공시형 → 논란형 → 화제형 → 기타. 분석에는 **화제형**을 쓰고(H3), 논란형은 파일럿 기준 통과 시 별도 변수, 공시형은 일단 제외(선택지는 아래).

팀이 먼저 정할 것 (11/10 시험 100건에서 나온 문제):

정할 것	왜
사회공헌·수상·후원 기사 = 광고? 화제형?	시험 100건 중 28건이 여기에 해당. 어느 쪽이냐에 따라 화제형 수가 크게 바뀜
복합=Y 기사 처리	"유상증자가 논란" → 순서 규칙상 공시형이지만 교수님 예시는 논란형. 복합=Y는 사람이 최종 판단하는 규칙 추가 권장
시황·증권사 리포트·주가 기사	주가로 쓰인 기사는 수익률 정보가 섞여 쓰지 않는 게 원칙 → "기타"로 고정
공시형 처리	(가) 제외 / (나) 별도 변수 / (다) 실적 서프라이즈만 화제형으로

시험 절차: ① 2단계를 통과한(제목 매칭된) 기사에서 **여러 회사·여러 연도**로 새 100건 무작위(시드 고정). 지난 파일럿 100건과 겹치지 않게. ② 두 사람이 **서로 보지 않고** 정답을 단다. ③ 두 사람이 다른 기사는 셋째 사람이 결정. ④ 분류기(LLM 또는 키워드 규칙)와 비교.

11/10 예비 결과: LLM 분류(팀 지시문)와 키워드 규칙 v1의 일치율 35% → 키워드 v1은 그대로 못 씀. 전체 기사를 외부 LLM에 넣는 것은 빅카인즈 이용 조건 확인 후 결정.

> 게이트: 분류기와 사람 정답 일치 80% 이상, 화제형에 대해서는 따로 정밀도(화제형이라고 한 것 중 진짜 화제형 비율)도 80% 이상. 미달이면 규칙·지시문을 고치고 **새** 100건으로 다시(같은 100건 재사용 금지: 점수가 부풀려짐).

4. 감성 점수

- KR-FinBert-SC 그대로(재학습 금지). 입력 = 제목 + 본문 200자. s = P(긍정) − P(부정), −1~+1.
- Colab T4 GPU에서 실행(노트북 `4팀_뉴스점수_Colab.ipynb`). 기사별 점수를 캐시해 끊겨도 이어서.
- 모델 버전(커밋)을 기록한다.

> 게이트: 누가 봐도 긍정(예: "사상 최대 실적"), 부정(예: "압수수색") 기사 각 15건에서 부호가 맞는지 확인. 20% 넘게 틀리면 입력(제목만 vs 제목+본문)을 바꿔 비교.

5. 월 배정과 집계

- 그달 **마지막 거래일 당일과 그 이후** 기사는 다음 달로(그날 종가에 이미 반영됐는지 알 수 없으므로).
- 종목×월로 묶어: 화제형 평균 논조(`topic_tone`), 화제형 기사 수, 공시형·논란형 수와 논조.
- 원문은 여기서 버리고, **숫자만** 드라이브 밖으로 나온다(`news_monthly.csv`, `news_coverage.csv`).

> 게이트: 연도별·회사별 기사 수 그래프에서 갑자기 0이 되는 구간 확인 → 수집 누락이면 0단계로.

6. 판정 (H3·H4)

- **평가 대상:** 매년 직전 연도 말 시총 상위 100 중 그해 기사가 수집된 종목.
- **H3 쓸모:** 3단계(수급까지) + 화제 논조 + 화제 기사 없음 표시 = 4단계. 평균 IC↑ & 11년 중 6년.
- **H3 방향:** Fama-MacBeth에서 화제 논조 계수가 + 이고 $t \geq 2$. 논조 3분위 표(상−하)도 같이.
- **H4:** 호재 종목(화제 기사 있고 논조가 그달 중간값 초과) 안에서 개인 많음 − 적음, 빼기 기사 없는 종목 안의 같은 차이. − 이고 $t \leq -2$ → 지지. 강건성: 호재 기준 "논조 > 0", 대형/소형 분리.

> 게이트: 판정 규칙은 지금 문서 그대로 고정. 결과를 보고 호재 기준이나 분위 수를 바꾸지 않는다.

H1 결과가 뉴스 분석에 주는 의미

> H1에서 개인 순매수가 **+**(개인이 산 종목이 다음 달 더 오름)로 나왔다. 그래서 H4에서 "호재 종목 안 개인 많음 − 적음"만 보면 그냥 H1의 + 효과가 보일 가능성이 크다. **기사 없는 종목에서의 같은 차이를 빼는(차이의 차이)** 설계가 그래서 필수다. 호재일 때만 + 가 줄거나 − 로 뒤집히면 그것이 "호재에 개인이 몰리면 더 약하다(설거지)"의 증거다.

일정과 역할

날짜	할 일	담당(제안)
11/11~13	3단계 규칙 결정(광고·복합·시황), 2단계 매칭 50건 확인	팀 회의 / 정아영
11/14~16	분류 시험 2차: 새 100건, 사람 2명 정답 → 80% 확인	위영섭·정아영
~11/22	수집 마감(담당 3·4 잔여)	담당 3·4
11/22~24	노트북 전체 실행 → 감성 점수 → 집계 파일	하이안
11/25	H3·H4 판정, 변수·설정 고정	전원

파일: Colab 노트북 `연습장/news/4팀_뉴스점수_Colab.ipynb`, 처리 코드 `연습장/news/news_core.py`, 판정 코드 `연습장/step9_news_h3h4.py`. 원문 데이터와 사람 확인용 샘플(제목 포함)은 비공개 드라이브에만.