4팀 변수 판정 해설서

기준선 → 통제 → 보강 → 수급(H1·H2)
데이터를 열어 보고, 규칙을 먼저 정하고, 실제로 찍어 본 기록

금융데이터인텔리전스(2026-2) 4팀 · 2026-11-10 실행 · 검증 구간 2011~2021 (131개월)

한 쪽 요약

1. **남은 변수:** 베타·규모·가치(기준선, 판정 면제) + 단기 반전·모멘텀(통제) + 고유변동성(보강) + 개인·외국인 순매수(수급). **주식 발행**은 혼자서는 예측을 전혀 못 올려 탈락 후보.
2. **예측력(평균 IC):** 0.051 → 0.077 → 0.088 → 0.092. 네 단계 모두 "평균 IC↑ & 11년 중 6년 이상↑" 규칙 통과. 정답을 섞은 누수 점검은 −0.001(0 근처, 정상).
3. **H1(개인이 사면 약하다): 반대로 나옴.** 개인이 많이 산 종목이 다음 달 0.70%p 더 높음(t +3.1). 다른 변수를 다 같이 넣어도(Fama-MacBeth t +3.1), 극단값·퇴장 종목·거래정지를 바꿔 넣어도 그대로.
4. **H2(외국인이 사면 강하다): 확인하지 못함**(t −1.2). 2002~2021로 넓히면 오히려 반대 방향(t −2.7).
5. **쏠모와 방향은 따로:** 개인 순매수는 방향은 가설과 반대지만, 알면 예측이 좋아짐(11년 모두 개선). 그래서 "변수는 남기고, 가설은 기각"이 동시에 성립.
6. **주의:** 예측력은 대부분 중소형주에서 나옴(시총 상위 100 안에서는 IC 0.023).

1. 처음 보는 사람을 위한 용어 6개

용어	뜻 (쉬운 말)
t월, t+1월	t월 = "이번 달", t+1월 = "다음 달". 우리는 **이번 달 말까지 알 수 있는 정보**로 **다음 달 수익률 순위**를 맞힌다.
순위(0~1)	매달 종목들을 줄 세워 꼴찌 0, 1등 1로 바꾼 값. 단위가 다른 변수(원, %, 배)를 같은 자로 재기 위해 쓴다. 극단값(예: +1,600%)도 그냥 "1등"이 되어 영향이 줄어든다.
IC (정보계수)	매달 "우리가 매긴 순위"와 "실제 다음 달 수익률 순위"가 얼마나 비슷한지(Spearman 순위상관). 1이면 완벽, 0이면 동전 던지기, −1이면 정반대. **주식에서는 0.05만 넘어도 쓸모 있는 수준**으로 본다.
5분위	매달 변수 값으로 종목을 5줄로 나눔(하위 20% = 1분위 … 상위 20% = 5분위). 각 줄의 다음 달 평균 수익률을 막대로 그리면 방향이 눈에 보인다. "Q5−Q1" = 5분위 − 1분위 차이.
t값	"이 차이가 우연일 가능성이 얼마나 낮은가". 월별 값의 평균 ÷ 흔들림(표준오차). |t|≥2면 우연으로 보기 어렵고(약 95%), |t|≥3이면 거의 확실(약 99.7%).
Fama-MacBeth	매달 "다음 달 수익률 = 여러 변수의 합" 회귀를 따로 돌리고, 계수의 월평균과 t값을 본다. **다른 변수를 같이 넣은 상태에서** 그 변수 하나의 방향(+/−)을 확인하는 도구.

2. 판정 규칙 — 결과를 보기 전에 정했다

교수님 피드백: "예상이 아니라 결과", "결론을 정해 두지 말고 데이터로 확인하라". 그래서 **숫자를 보기 전에** 아래 규칙을 고정했다. 결과를 보고 규칙을 바꾸면 원하는 결론을 만들 수 있기 때문이다.

질문	도구	규칙
쓸모 이 변수를 알면 예측이 좋아지나?	XGBoost 누적 학습 → 단계별 IC	직전 단계보다 **① 검증 131개월 평균 IC가 오르고 ② 11개 검증 연도 중 6년 이상 연평균 IC가 오르면** OK. 둘 중 하나라도 못 하면 NO. 기준선(베타·규모·가치)은 출발점이라 판정 면제.
방향 가설이 말한 쪽(+/−)인가?	Fama-MacBeth, 5분위 표	부호가 가설과 같고 |t|≥2 → **어느 정도 지지**, |t|≥3 → **확실하게 지지** 부호가 반대이고 |t|≥2 → **반대 방향으로 유의** |t|<2 → **확인하지 못함** ("틀렸다"가 아님)
참고	증가분 t	매달 (이번 단계 IC − 직전 단계 IC)의 평균 ÷ 표준오차. 판정에는 쓰지 않고 참고로만 적는다.

왜 쓸모와 방향을 따로 보나?
XGBoost는 계수가 없는 "나무" 모형이라 변수가 +인지 −인지 말해 주지 않는다. "이 정보를 알면 줄 세우기가 나아지나"만 알려 준다. 반대로 Fama-MacBeth는 방향은 알려 주지만 비선형 관계는 놓친다.
비유: 일기예보에서 "습도"는 비가 올지 말지를 맞히는 데 쓸모가 있다(쓸모). 그런데 "습도가 높으면 비가 온다"는 가설이 맞는지는 따로 확인해야 한다(방향). 습도가 높을수록 비가 *덜* 오는 이상한 동네라도, 습도는 여전히 예보에 쓸모 있다.
→ 그래서 **"변수는 남는다(쓸모 OK)" + "가설은 반대로 나왔다(방향 반대)"**가 동시에 가능하다. H1이 바로 이 경우다.

질문: XGBoost IC에도 t≥2 규칙을 똑같이 쓰나? → 아니다. XGBoost의 IC 자체는 거의 항상 t가 크다(예: 기준선만으로 t 6.2). 우리가 궁금한 건 "더했을 때 나아졌나"라서 **증가분**과 **이긴 해 수**로 판정한다. 증가분 t는 참고로 적어 두고, 11/16에 교수님께 보조 근거로 써도 되는지 묻는다.

3. 데이터 열어 보기 — 무엇을 열었고, 무엇이 눈에 띄었나

파일 (출처: 팀 드라이브, 은예원)	내용
`joined_investor.csv` (33MB)	배포 데이터(월 수익률·시가총액·주가·주식 수)에 개인·외국인 순매수 금액과 비율을 붙인 long 파일. 2000-01~2021-12, 264개월 × 1,086종목 = 286,704줄.
`monthly_pbr_2000_2025.csv` (27MB)	월별 PBR. 가치 변수(1/PBR)용. KOSPI 밖 종목도 있음.
`RiskFree_Rate_CD91.csv`	CD 91일물 금리(연 %). 베타·고유변동성의 초과수익률 계산용.

기본 점검 결과: 월+종목 중복 0건, 시가총액 0 이하 0건, 수익률 있는데 시총 없는 칸 0건. 순매수 비율(`retail_to_mcap`)을 "t월 순매수 ÷ t−1월 시총"으로 직접 다시 계산해 보니 파일 값과 오차 0 → **예원님 매칭은 정확**. 순매수가 채워진 비율은 모든 연도에서 99.9~100%(이전에 걱정했던 "외국인 555종목 vs 개인 835종목" 문제는 이 파일에서 해결됨).

그림 0. 데이터 지도: 무엇이 언제 비어 있고, 어디가 튀는가

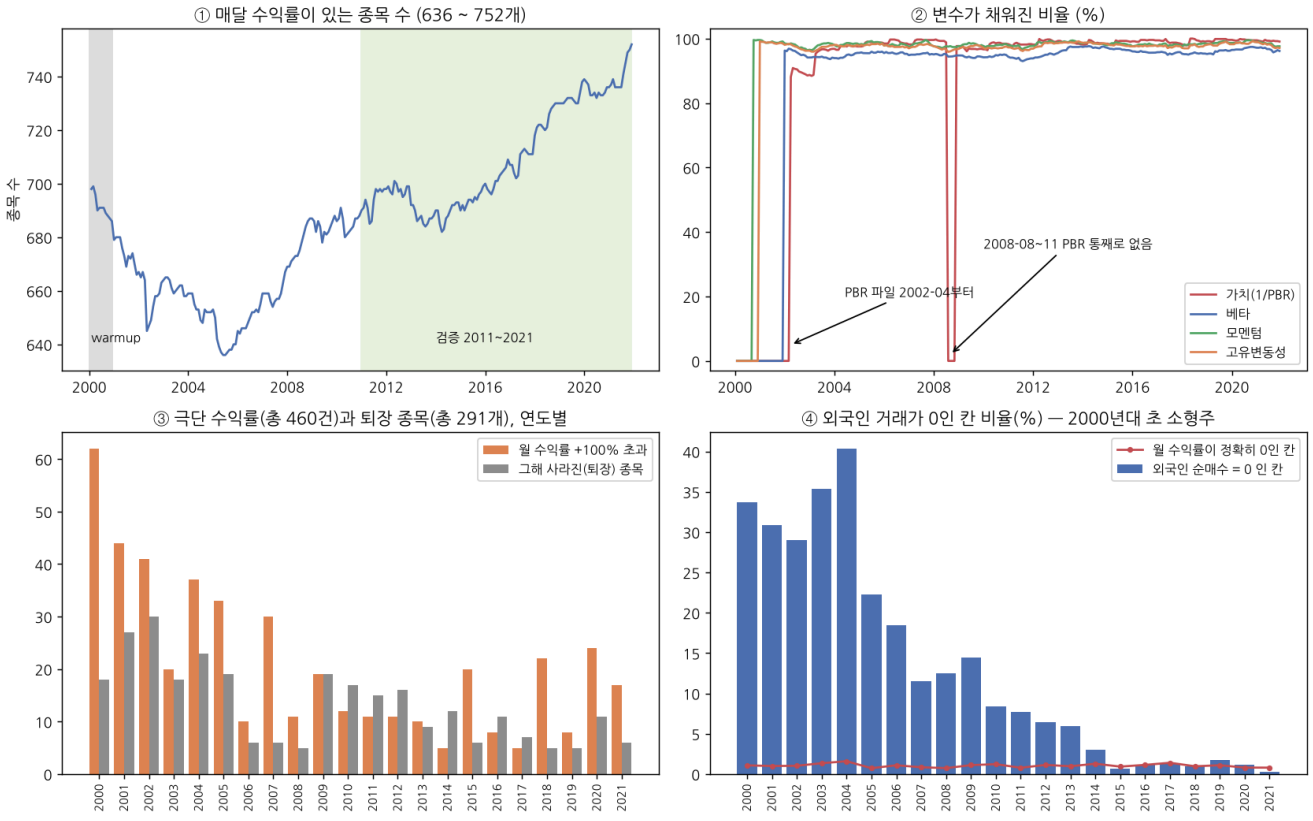


그림 0. 데이터 지도

그림 0 읽는 법

① **종목 수**: 매달 수익률이 있는 종목은 636개(2005-06)~752개(2021-12). 2005년 바닥 후 꾸준히 늘었다. 회색 = 2000년 warmup(변수 계산용, 학습·평가 제외), 연두 = 검증 구간.

② **변수 채움 비율**: 빨간 선(가치)이 2002년 4월 전에 0%, 그리고 2008년 가을에 **4개월 동안 0%로 뚝 떨어진다**. 파란 선(베타)은 60개월 중 최소 24개월이 쌓여야 계산되므로 2002년부터 시작.

③ **극단 수익률과 퇴장**: 한 달에 +100% 넘게 오른 칸(주황)이 2000~2005년에 몰려 있다. 회색은 그해 데이터에서 사라진(상장폐지 등) 종목 수.

④ **외국인 0**: 2000~2004년에는 칸의 22~40%에서 외국인 순매수가 정확히 0 → 외국인이 아예 거래하지 않은 소형주. 2015년 이후는 1~2%.

주목할 점 14가지 — 무엇이 결과에 영향을 줄 수 있고, 어떻게 처리했나

#	발견	왜 문제가 될 수 있나	처리와 결과에 준 영향
1	빈칸 37%(수익률 있는 칸 180,939 / 286,704)	빈칸을 0으로 읽으면 "수익률 0%"로 오해	상장 전·폐지 후의 **구조적 빈칸**. 수익률이 있는 칸만 분석 대상. 영향 없음.
2	1,086종목 중 43개는 수익률이 한 번도 없음	종목 수를 부풀림	자동으로 빠짐(실제 분석 1,043종목).
3	중간에 사라진 종목 291개, 새로 생긴 종목 약 340개	살아남은 종목만 있으면 "생존 편향"(망한 회사가 빠져 수익률이 부풀려짐)	퇴장 종목도 **퇴장 전까지** 데이터에 있음 → 생존 편향은 작다. 매달 "그달 있던 종목"만 고르고, 오늘 기준으로 종목을 고르지 않았다.
4	퇴장 직전 달은 "다음 달 수익률"이 없음: 422줄(0.24%)	망하기 직전 큰 손실이 빠지면, 그 종목을 많이 산 쪽이 좋아 보일 수 있음(특히 H1)	평가에서 빠짐. **점검**: 사라진 수익률을 −30%, −100%로 채워도 H1 계수는 +0.82(t 3.3), +0.96(t 3.4)로 **오히려 커짐** → 결론 영향 없음(8절 표).
5	월 +100% 초과 460건(최대 +1,623%, 2000-02), −90% 이하 46건	평균을 쓰는 계산(5분위 평균, Fama-MacBeth)을 몇 종목이 흔듦	지우지 않음(진짜일 수 있음: 감자·재상장 등 → 예원님 확인 요청). XGBoost 정답과 IC는 **순위**라 영향 작음. Fama-MacBeth는 매달 상하위 1%를 잘라도 H1 t 2.8로 유지.
6	수익률이 정확히 0인 칸 1,896건(매년 약 1%)	거래정지 종목일 수 있음 → 가짜 신호	제외하고 다시 해도 H1 +0.79(t 3.2) 동일.
7	한 종목의 수익률이 중간에 끊긴 구간 156건	끊긴 뒤 수익률을 "다음 달"로 착각하면 미래 정보 누수	정답(target)은 **바로 다음 달 줄이 있을 때만** 만든다. 몇 달 건너뛴 수익률은 정답으로 쓰지 않음.
8	PBR 파일이 **2002-04부터**만 있음	2001-01~2002-03 가치 변수 없음	학습 첫 구간(2001~2010) 가치 결측 18.7%. 빈칸은 순위 0.5(중간) + "결측 표시 열"을 넣어 모델이 "모름"을 알게 함. **검증 구간 결측은 0.9%**라 판정에는 영향 작음. Fama-MacBeth는 2002-04부터 시작.
9	**2008-08~11 PBR 4개월이 통째로 없음**	금융위기 한복판에 가치 정보가 없음	그 4개월은 결측 표시로 학습. 검증(2011~)에는 없음 → 판정 영향 없음. **보고서에 반드시 적을 것**(원인은 예원님 확인 요청).
10	PBR = 0인 칸 15.6%(2002~05년엔 49~64%), 음수는 0건	0이면 1/PBR = 무한대. 자본잠식이 0으로 들어갔을 가능성	PBR ≤ 0 → 결측. 2002~05년 가치 정보가 얇다는 점을 기록.
11	베타는 60개월(최소 24) 필요 → 2002-01부터, 신규 상장 종목은 첫 2년 결측	신규 종목이 체계적으로 빠짐	결측 표시 열로 처리. 검증 구간 베타 결측 4.1%.
12	외국인 순매수 = 0이 2000~04년 22~40%	결측인지 진짜 0인지	"외국인이 거래하지 않았다"는 **진짜 0**으로 둠. 검증 구간은 2.8%라 영향 작

			음. 다만 **2002~2021 전체로 H2를 볼 때**는 앞쪽 정보가 얇다는 점을 감안.
13	개인 순매수 비율이 시총의 50%를 넘는 칸 41건(최대 7.1배)	몇 칸이 H1 결과를 만들었을 수 있음	|순매수 비율| > 20% 칸을 빼도 H1 +0.78(t 3.2) 동일. 순위 변환으로 영향도 작음.
14	2021-12의 정답은 2022-01 수익률(=test)	test 정보 누수	2022년 이후는 읽자마자 버림 → 검증은 2011-01~2021-11 **131개월**(132가 아님).

추가로 알아 둘 것: 시장수익률은 KOSPI 지수가 아니라 이 데이터 종목의 **직전 달 시총 가중 평균**으로 직접 만들었다. 가장 큰 종목(삼성전자)의 시총 비중이 2001년 15.7% → 2021년 23.5%라, 베타는 "삼성전자와 얼마나 같이 움직이나"에 가깝게 된다(베타 해석 시 주의).

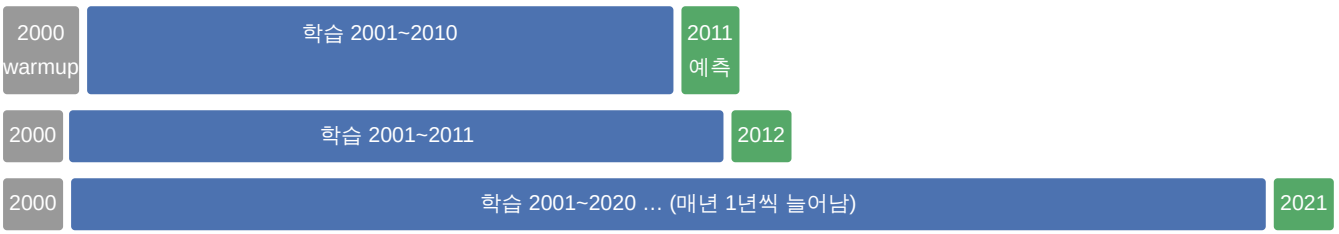
4. 변수 만들기 — 모두 "t월 말까지 알 수 있는 정보"

묶음	변수	만드는 법	예상 방향
기준선 교과서 위험 요인. 판정 면제	베타	최근 60개월(최소 24) 종목 초과수익률을 시장 초과수익률에 회귀한 기울기	+ (위험이 크면 보상)
	규모	ln(t월 말 시가총액)	− (작은 회사가 높음)
	가치	1/PBR (PBR ≤ 0은 결측)	+ (싼 주식이 높음)
통제 수급 효과와 섞이면 안 되는 것	단기 반전	t월 수익률	− (많이 오르면 되돌림)
	모멘텀	t−11 ~ t−1월 누적 수익률(t월 제외, 11개월 중 8개월 이상)	± (한국은 논쟁)
보강 옛 "유지 후보". 테마 밖이지만 평균 IC를 올려 다시 넣은 것	고유변동성	최근 24개월(최소 12) 시장모형 잔차의 표준편차	− (변덕스러운 주식이 낮음)
	주식 발행	ln(t월 주식 수 ÷ 12개월 전 주식 수)	− (주식을 많이 찍으면 낮음)
수급	개인 순매수 (H1)	t월 개인 순매수 금액 ÷ **t−1월 말** 시총	− (H1)
	외국인 순매수 (H2)	t월 외국인 순매수 금액 ÷ **t−1월 말** 시총	+ (H2)
정답	target	t+1월 수익률. 같은 종목의 **바로 다음 달** 줄에서만 가져옴	

모델에 넣을 때는 매달 순위(0~1)로 바꾸고, 빈칸은 0.5(중간) + 결측 표시 열(빈칸이면 1)로 채운다. 결측을 0으로 채우지 않는 이유: 0은 "가장 작은 값"이라는 다른 뜻이 되기 때문이다.

5. 학습 방식 — 매년 쌓는 누적 학습

모의고사 비유: 2001~2010년 기출문제로 공부해서 2011년 모의고사를 친다. 채점 후, 2011년까지 포함해 다시 공부하고 2012년을 친다. 이렇게 2021년까지 11번 반복한다.



- **학습에 쓰는 줄:** Y년을 예측할 때는 2001-01 ~ (Y−1)년 11월 줄까지만. 11월 줄의 정답은 12월 수익률이라 Y년 1월 초에 이미 알 수 있다. 12월 줄의 정답(Y년 1월 수익률)은 아직 모르므로 쓰지 않는다.
- **재학습:** 1년에 한 번(1월). 그 공식 하나로 그해 12개월을 모두 예측.

- **XGBoost 설정은 고정:** 나무 300그루, 깊이 4, 학습률 0.05, 표본 80%, 시드 42(config.yaml 값). 결과를 보고 튜닝하지 않는다(과적합 방지).
- **정답의 형태:** 다음 달 수익률 자체가 아니라 그달 안의 순위. +1,600% 같은 극단값에 모델이 끌려가지 않게 하고, 평가(IC)도 순위로 하기 때문.
- **test(2022~2025)**는 11/25에 설정을 고정한 뒤 딱 한 번만 쓴다(같은 방식으로 매년 쌓는 것은 교수님이 허용).

6. 첫 단계: 방향 미리 보기 (학습 없음)

모델을 돌리기 전에 변수를 **하나씩** 5분위로 나눠 다음 달 수익률을 본다. 판정용이 아니라 "데이터가 대략 어느 쪽을 가리키나"를 눈으로 보는 단계다.

그림 A. 변수 5분위별 다음 달 평균 수익률 (2011~2021, 학습 없는 방향 미리 보기)

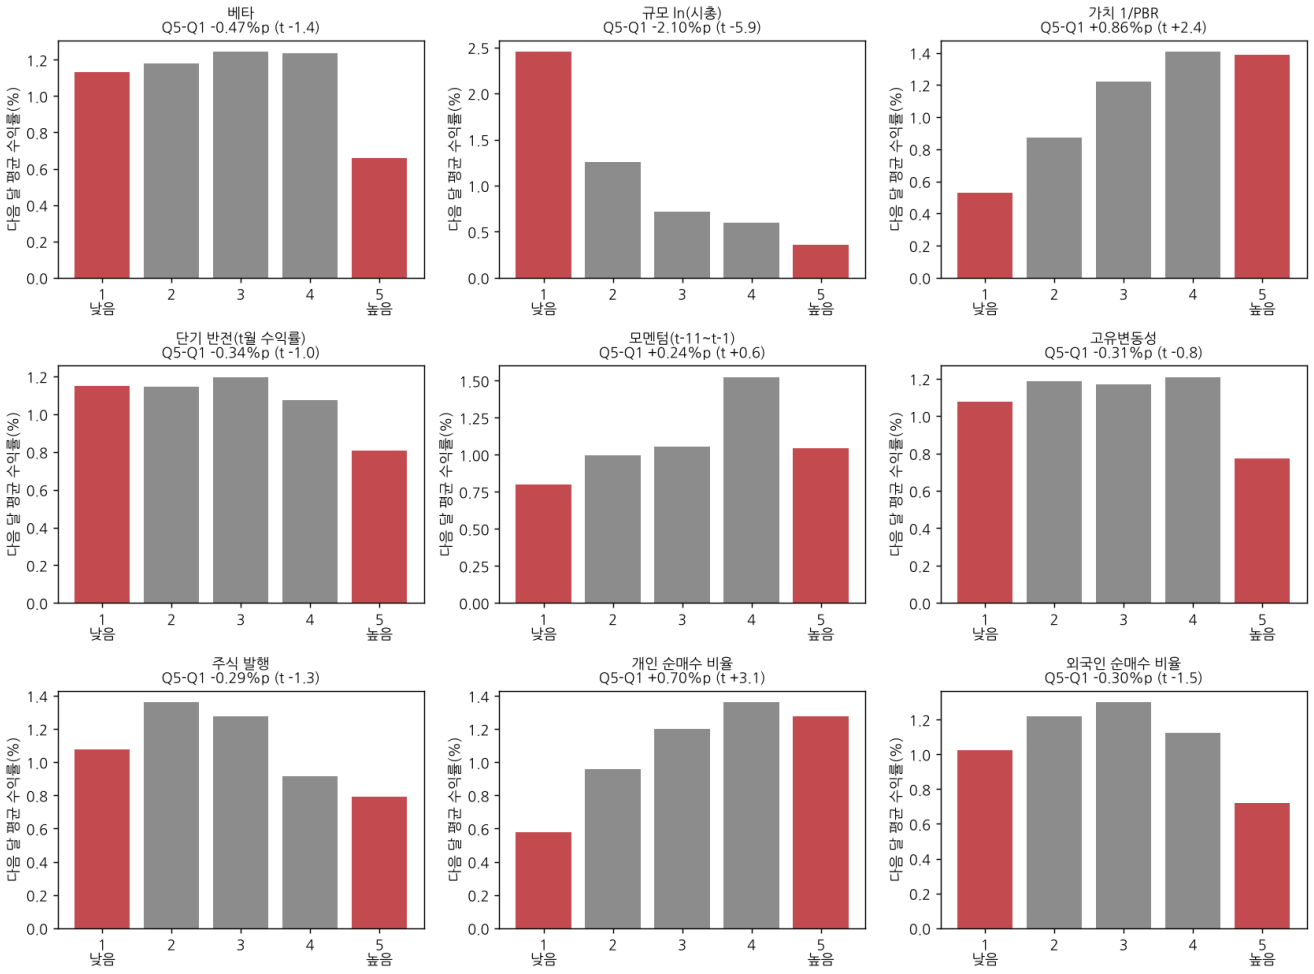


그림 A. 변수 5분위별 다음 달 평균 수익률(2011~2021)

그림 A 읽는 법 — 각 칸은 변수 하나. 가로축 1(그 변수가 가장 낮은 20%) → 5(가장 높은 20%), 세로축은 그 종목들의 **다음 달** 평균 수익률. 빨간 막대 두 개(1과 5)의 차이가 제목의 Q5−Q1이다. 계단이 오른쪽으로 올라가면 +, 내려가면 − 방향.

눈에 띄는 것: 규모는 1분위(가장 작은 회사)가 2.45%로 튀고 나머지는 계단식 하락(Q5−Q1 −2.10%p, t −5.9). **가치**는 깔끔한 오르막(+0.86%p). **개인 순매수**도 오르막(+0.70%p, t +3.1) — **H1 예상(내리막)과 반대**. **외국인 순매수**는 가운데가 높고 5분위가 낮은 산 모양(−0.30%p, t −1.5). **베타·고유변동성**은 1~4분위는 비슷하다가 5분위만 뚝 떨어지는 "꼬리 모양" — 가장 위험한 20%만 나쁘다.

변수	예상	원시 IC 2011~21 (t)	Q5−Q1 %p (t)	한 줄 해석
베타	+	−0.030 (−2.6)	−0.47 (−1.4)	예상과 반대. 저베타 이상현상(Frazzini & Pedersen 2014)
규모	−	−0.018 (−1.6)	−2.10 (−5.9)	방향은 맞지만 극소형 1분위가 대부분
가치	+	+0.054 (+4.9)	+0.86 (+2.4)	가장 깔끔한 단일 신호
단기 반전	−	−0.036 (−3.5)	−0.34 (−1.0)	순위로는 꾸준, 평균 차이는 작음
모멘텀	±	+0.007 (+0.6)	+0.24 (+0.6)	최근 한국에선 거의 없음
고유변동성	−	−0.076 (−6.2)	−0.31 (−0.8)	**순위 신호는 가장 강함**(IC 기준 1등)
주식 발행	−	−0.035 (−6.4)	−0.29 (−1.3)	방향은 맞음
개인 순매수	−	+0.018 (+2.7)	+0.70 (+3.1)	**H1과 반대**
외국인 순매수	+	−0.009 (−1.6)	−0.30 (−1.5)	H2 방향 아님, 유의하지 않음

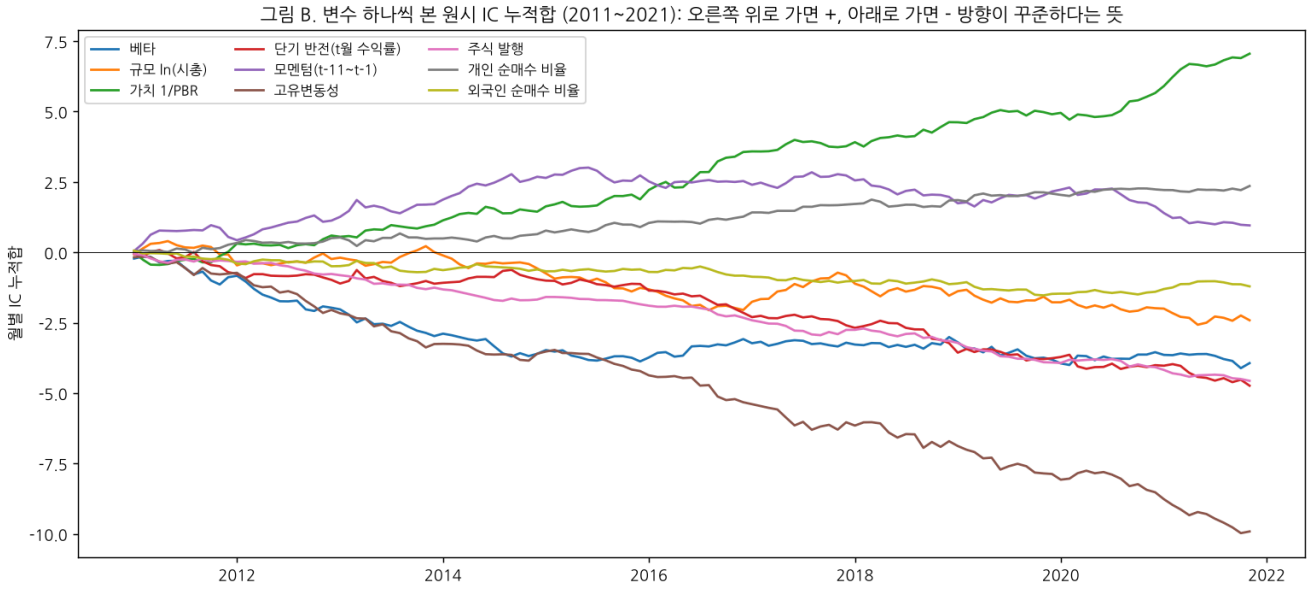


그림 B. 변수 하나씩 본 원시 IC 누적합

그림 B 읽는 법 — 매달 IC를 계속 더해 간 선. **꾸준히 한쪽으로 기울면 매달 같은 방향이 반복된다는 뜻**(우연이 아님). 선이 오르락내리락하며 0 근처면 신호가 없다. 고유변동성(아래로 가장 가파름)·가치(위로)·주식 발행·단기 반전(아래로)은 꾸준하다. 모멘텀과 외국인 순매수는 0 근처를 맴돈다. 개인 순매수는 완만하게 위로 올라간다.

> 이 단계의 숫자는 **판정에 쓰지 않는다**. 변수 하나만 봤기 때문에 서로 겹치는 정보(예: 규모와 가치)를 구분하지 못한다. 판정은 7절(XGBoost)과 8절(Fama-MacBeth)에서 한다.

7. 쓸모 판정: XGBoost 누적 학습 단계별 IC

변수를 묶음 단위로 하나씩 더하면서 매번 5절의 누적 학습을 처음부터 다시 돌린다. 각 단계의 131개월 IC를 직전 단계와 비교한다.

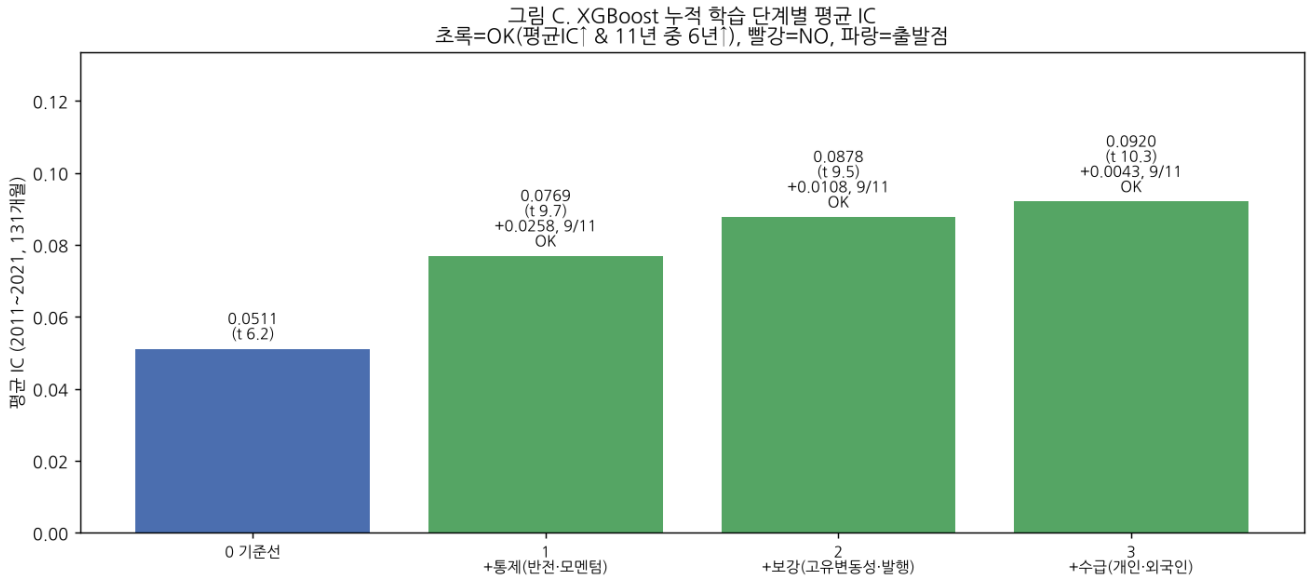


그림 C. 묶음 단계별 평균 IC

그림 C 읽는 법 — 막대 높이 = 그 단계까지 넣은 모델의 평균 IC. 막대 위 숫자는 위에서부터 평균 IC, (t), 직전 단계 대비 증가분, 이긴 해 수, 판정. 초록 = 규칙 통과, 파랑 = 출발점.
기준선만으로 0.051. 통제를 더하면 0.077로 **가장 크게** 오른다(+0.026, 11년 중 9년). 보강 +0.011(9년), 수급 +0.004(9년). 오르는 폭이 점점 줄어드는 것은 자연스럽다(쉬운 정보부터 먼저 들어가기 때문).

단계	평균 IC	t	IC>0인 달	증가분 (t)	이긴 해	판정
0 기준선	0.0511	6.2	70%	—	—	출발점
1 + 통제	0.0769	9.7	81%	+0.0258 (5.5)	9/11	**OK**
2 + 보강	0.0878	9.5	83%	+0.0108 (3.6)	9/11	**OK**
3 + 수급	0.0920	10.3	85%	+0.0043 (2.7)	9/11	**OK**
3a 보강 + 개인만	0.0925	10.5	85%	+0.0047 (3.3)	11/11	**OK**
3b 보강 + 외국인만	0.0895	9.6	82%	+0.0017 (1.2)	7/11	**OK(약함)**
누수 점검(정답 섞기)	−0.0013	−0.3	47%	0 근처 → 미래 정보 누수 없음		

3a·3b는 수급 묶음 안에서 누가 기여했는지 보려고 하나씩 넣어 본 것. 개인이 혼자 11년 모두 이겼고, 외국인은 혼자서는 증가분 t 1.2로 약하다(규칙상 OK지만 근거가 얇음).

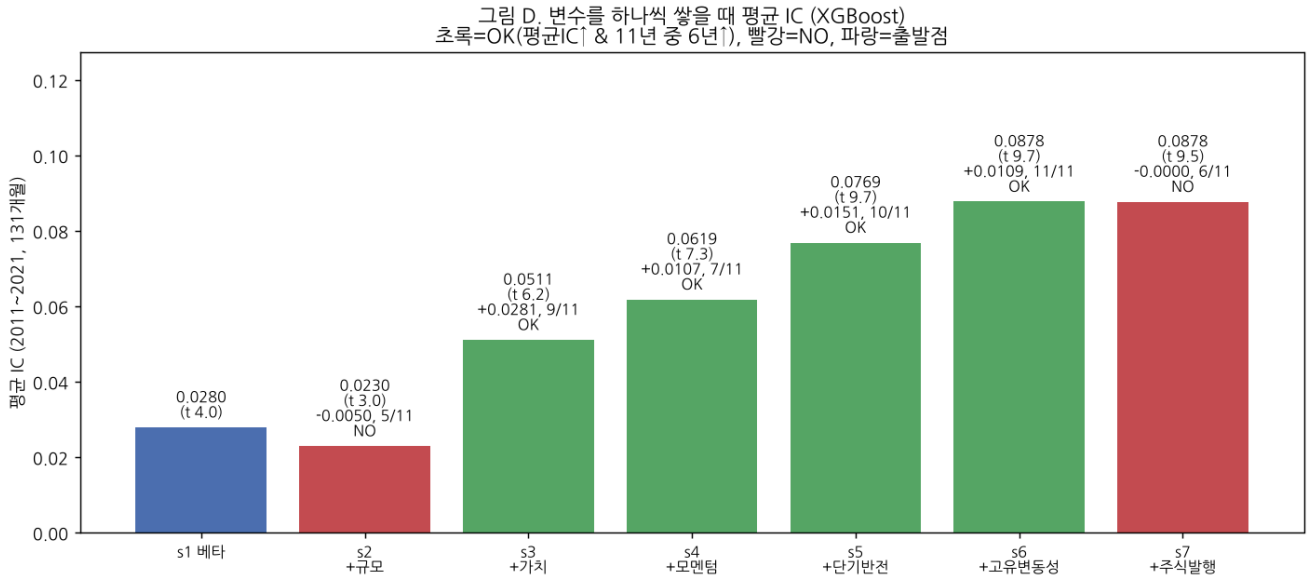


그림 D. 변수를 한 개씩 쌓을 때 평균 IC

그림 D 읽는 법 — 그림 C를 변수 하나 단위로 쪼갠 것. 빨간 막대는 규칙 탈락.
베타만으로 0.028 → **+규모**에서 오히려 0.023으로 **떨어짐**(NO) → **+가치**에서 0.051로 크게 오름 → **+모멘텀** 0.062 → **+단기 반전** 0.077 → **+고유변동성** 0.088(11년 모두 이김) → **+주식 발행** 0.0878로 **변화 없음**(NO).

규모는 왜 NO인데 남나? 규칙상 기준선은 판정 면제다(교과서 위험 요인이라 빼면 "규모 효과를 수급 효과로 착각"할 수 있음). 게다가 다른 변수와 함께 넣은 Fama-MacBeth에서는 규모가 9개 변수 중 가장 강하다(t −6.1, 8절). 베타 바로 뒤에 혼자 들어갈 때는 순위 관계가 약해 손해였지만, 가치(규모와 상관 −0.31)와 함께 있을 때 제 역할을 한다.
주식 발행은 왜 NO인가? 11년 중 6년은 이겼지만(규칙 ②는 통과) 평균 IC 증가분이 −0.0000(규칙 ① 실패). 고유변동성과 순위상관 0.21로 겹쳐서, 고유변동성이 이미 들어간 뒤에는 새로 알려 주는 것이 없다. 방향 자체는 맞다(2002~2021 Fama-MacBeth t −3.2).

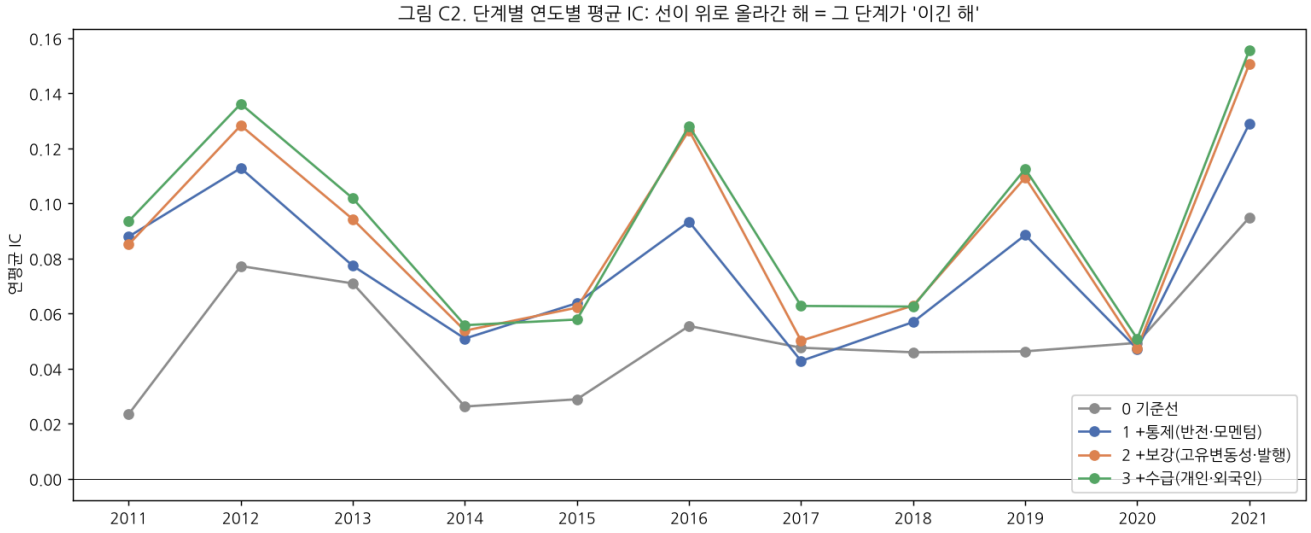


그림 C2. 단계별 연도별 평균 IC

그림 C2 읽는 법 — 점 하나 = 그해 12개월 평균 IC. 한 해에서 위쪽 선이 아래쪽 선보다 높으면 그 단계가 "이긴 해". 회색(기준선) 위로 파랑(통제)이 2011~2013, 2016, 2018~2021에 확실히 올라간다. 주황(보강)과 초록(수급)은 파랑 위에 겹쳐 조금씩 높다. **2014·2015·2020년은 통제 이후 세 선이 0.05~0.06에 몰려 있다** — 이 해들은 변수를 더 넣어도 나아지지 않았다. 특히 2020년은 기준선까지 네 선이 모두 0.05 근처로 겹친다(코로나 급락·급반등).

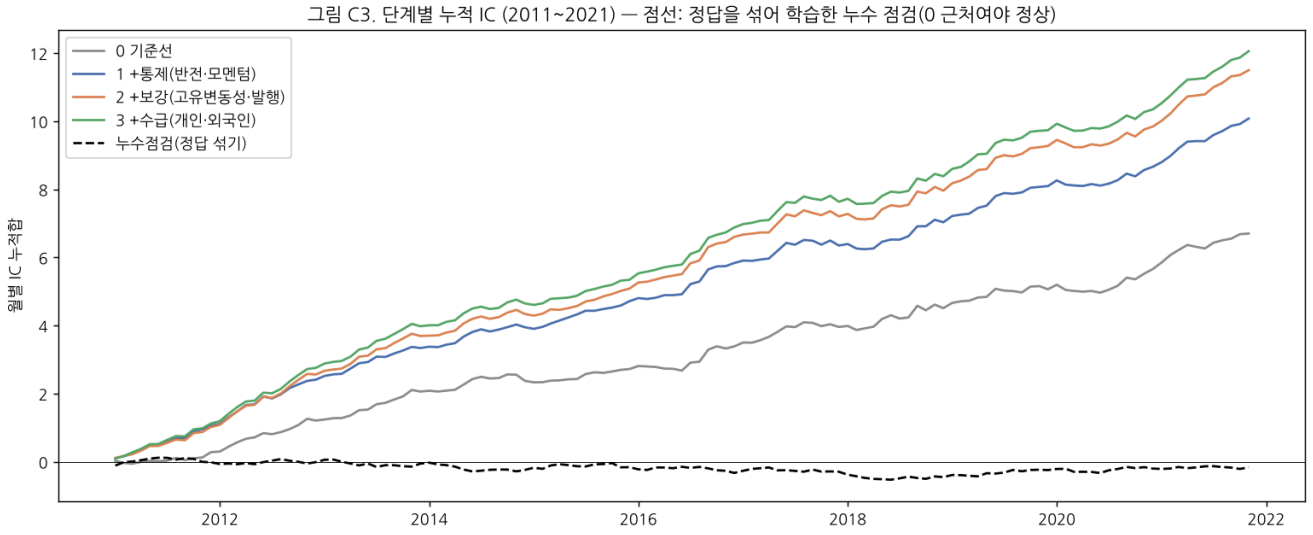


그림 C3. 단계별 누적 IC와 누수 점검

그림 C3 읽는 법 — 단계별 월 IC를 누적한 선. 네 선 모두 거의 직선으로 오른다 = 특정 몇 달이 아니라 **11년 내내 꾸준히** 맞혔다는 뜻. 선 사이 간격이 각 단계의 기여. **검은 점선**은 정답을 매달 무작위로 섞은 뒤 학습한 모델이다. 정답과 무관하게 학습했는데도 IC가 나온다면 코드 어딘가에서 미래 정보가 새고 있다는 뜻인데, 점선은 0 근처(−0.001)에 머문다 → **누수 없음**.

주의: 예측력은 중소형주에서 나온다. 같은 예측을 그달 시총 순위별로 나눠 평가하면 — 3단계 기준 전체 0.092, 시총 상위 100 **0.023**, 상위 200 0.038, 200위 밖 0.114. 대형주끼리는 순위를 맞히기 훨씬 어렵다. 보고서에는 전체 IC와 대형주 IC를 함께 적는다.

8. 방향 판정: H1·H2와 Fama-MacBeth

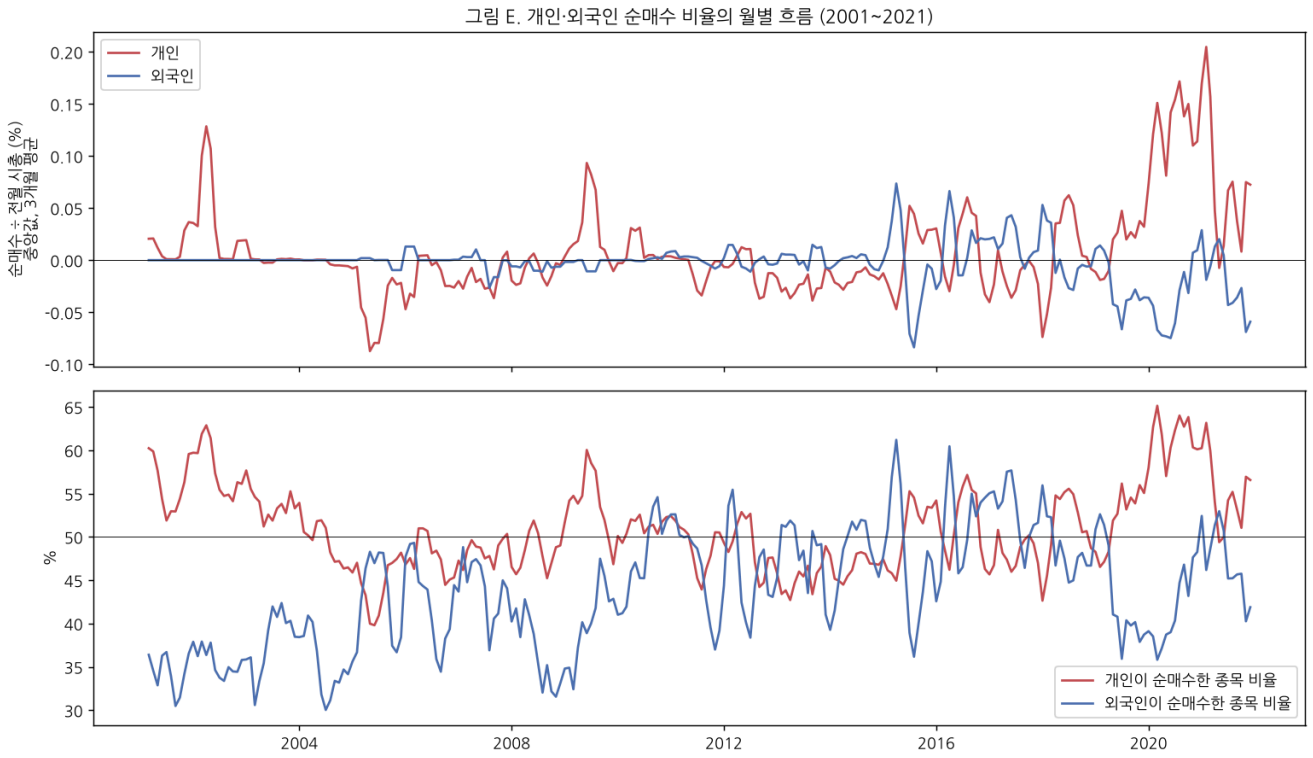


그림 E. 개인·외국인 순매수 비율의 월별 흐름

그림 E 읽는 법 — 위: 매달 종목들의 순매수 비율 중앙값(%, 3개월 평균). 아래: 그달 순매수(+)였던 종목의 비율.

두 선이 거울처럼 움직인다: 개인이 사는 달에 외국인은 판다(같은 달 두 변수의 순위상관 −0.47). 2005년 이전 외국인 선이 0에 붙어 있는 것은 3절 #12(외국인 무거래 소형주). 2020~2021년 개인 순매수가 급증한 구간이 "동학개미"다. 아래 그림에서 개인은 대부분 기간 50% 근처 이상, 외국인은 2000년대 초 30%대 → 대부분 종목에서 외국인은 순매도였다.

그림 F. H1·H2 수급 표: 순매수 비율 5분위별 다음 달 수익률 (2011~2021)

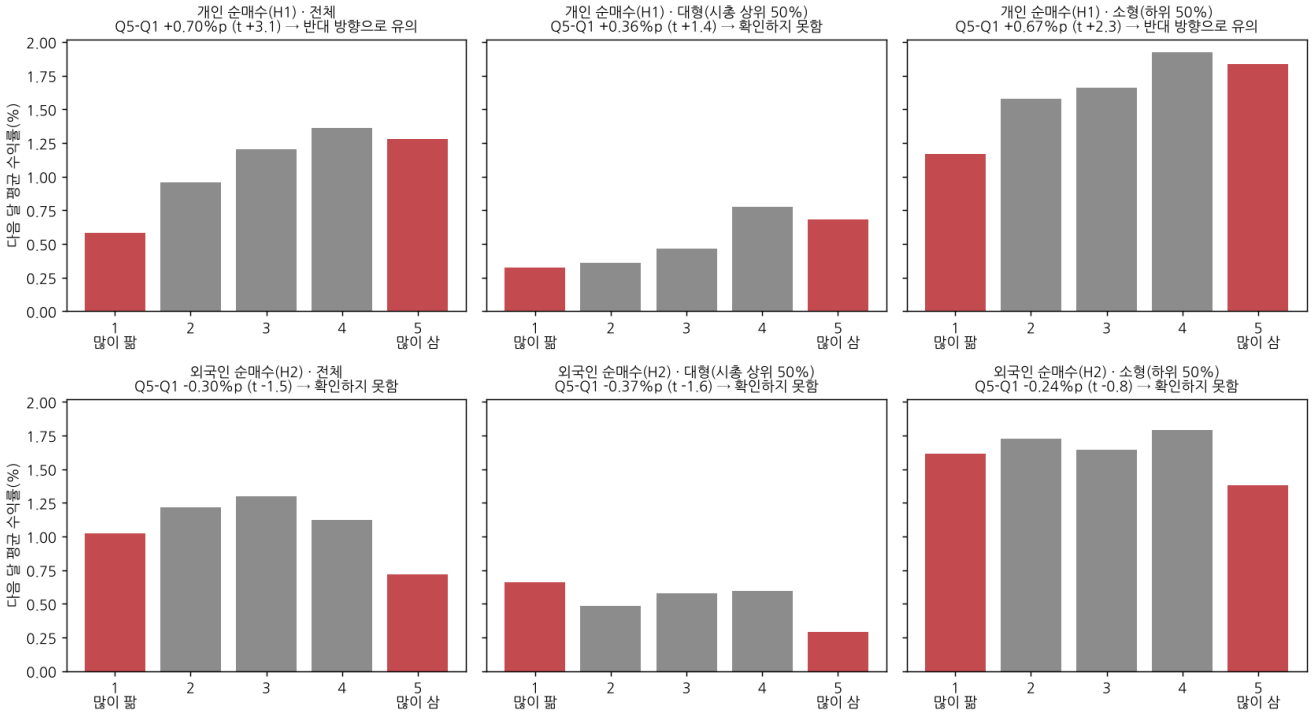


그림 F. H1·H2 수급 표(2011~2021)

그림 F 읽는 법 — 위 줄 개인, 아래 줄 외국인. 왼쪽부터 전체 / 시총 상위 50%(대형) / 하위 50%(소형). 가로축 1 = 그달 가장 많이 판 20%, 5 = 가장 많이 산 20%.
개인: 세 칸 모두 오르막. 전체 Q5−Q1 +0.70%p(t +3.1), 소형 +0.67%p(t +2.3), 대형 +0.36%p(t +1.4, 유의하지 않음). H1은 "많이 산 쪽이 낮다"(내리막)였으므로 **반대**.
외국인: 5분위(많이 산 쪽)가 오히려 낮다. 하지만 t가 −0.8 ~ −1.6으로 2에 못 미쳐 **확인하지 못함**.

가설	그룹	Q1 많이 팖	Q5 많이 삼	Q5−Q1 %p	t	판정
H1 개인	전체	0.58	1.28	+0.70	+3.1	반대 방향으로 유의
	대형	0.32	0.69	+0.36	+1.4	확인하지 못함
	소형	1.17	1.84	+0.67	+2.3	반대 방향으로 유의
H2 외국인	전체	1.02	0.72	−0.30	−1.5	확인하지 못함
	대형	0.66	0.29	−0.37	−1.6	확인하지 못함
	소형	1.62	1.38	−0.24	−0.8	확인하지 못함

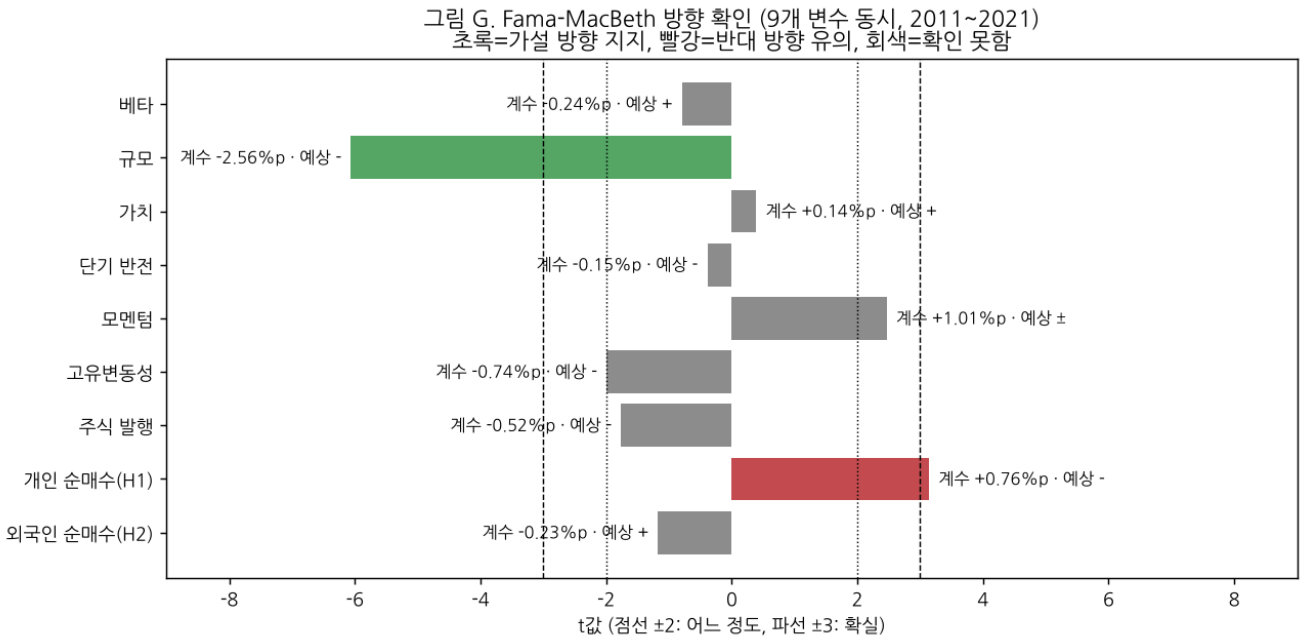


그림 G. Fama-MacBeth 방향 확인(9개 변수 동시, 2011~2021)

그림 G 읽는 법 — 막대 길이 = t값. 점선(±2)을 넘으면 "어느 정도", 파선(±3)을 넘으면 "확실". 색: 초록 = 가설 방향 지지, 빨강 = 반대 방향으로 유의, 회색 = 확인 못함. 옆 글씨의 "계수"는 **다른 8개 변수가 같을 때** 그 변수가 그달 꼴찌 → 1등으로 가면 다음 달 수익률이 몇 %p 달라지는지.
규모만 초록(−2.56%p, t −6.1). **개인 순매수는 빨강**(+0.76%p, t +3.1): 단기 반전·모멘텀·규모·가치·변동성을 모두 같이 넣어도 남는다. 외국인은 회색(t −1.2).

변수	예상	2011~21 계수 %p (t)	판정(검증 구간)	2002~21 계수 (t)
베타	+	−0.24 (−0.8)	확인하지 못함	+0.35 (+1.3)
규모	−	−2.56 (−6.1)	**확실하게 지지**	−2.05 (−5.2)
가치	+	+0.14 (+0.4)	확인하지 못함	+0.78 (+2.5)
단기 반전	−	−0.15 (−0.4)	확인하지 못함	−0.61 (−2.0)
모멘텀	±	+1.01 (+2.5)	통제(방향 가설 없음)	+1.51 (+4.6)
고유변동성	−	−0.74 (−2.0)	확인하지 못함(t −1.99)	−1.46 (−5.0)
주식 발행	−	−0.52 (−1.8)	확인하지 못함	−0.77 (−3.2)
개인 순매수 H1	−	**+0.76 (+3.1)**	**반대 방향으로 유의**	+0.54 (+2.8)
외국인 순매수 H2	+	−0.23 (−1.2)	확인하지 못함	−0.40 (−2.7) 반대

9개를 한꺼번에 넣으면 서로 겹치는 변수(가치·고유변동성·규모)는 t가 나뉘어 작아진다. 그래서 가치·단기 반전은 검증 구간에서 "확인 못함"이지만, XGBoost에서는 분명히 쓸모가 있었다(7절). 이것도 "쓸모와 방향은 따로"의 예다.

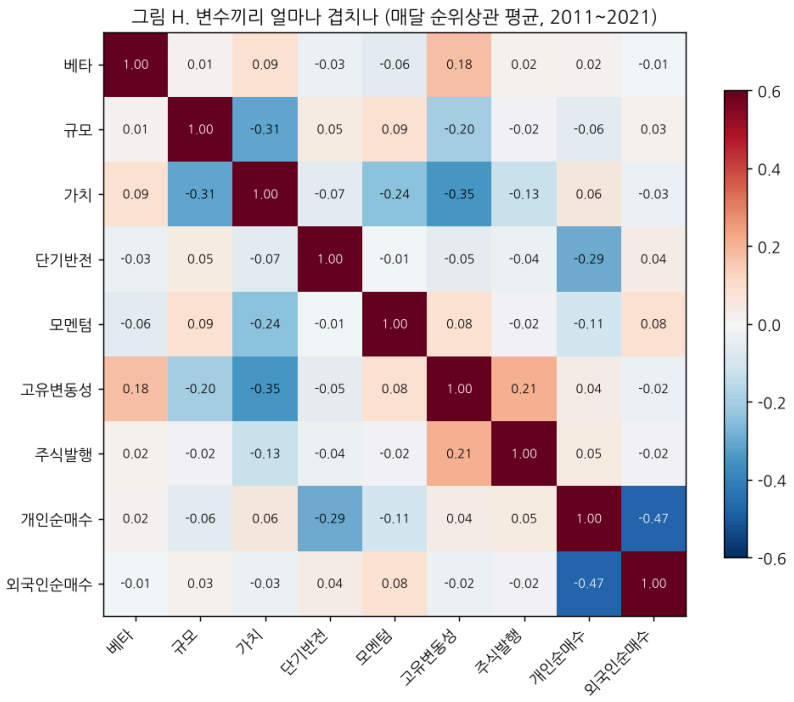


그림 H. 변수끼리의 겹침

그림 H 읽는 법 — 칸 숫자 = 두 변수의 월별 순위상관 평균. 빨강은 같이 움직임, 파랑은 반대로 움직임. **개인 순매수 ↔ 외국인 순매수 −0.47**(서로 반대편에서 거래), **개인 순매수 ↔ 단기 반전 −0.29**(개인은 그 달 **떨어진** 종목을 산다), 가치 ↔ 고유변동성 −0.35, 가치 ↔ 규모 −0.31. 이 겹침 때문에 하나씩 볼 때와 같이 볼 때 결과가 달라진다.

H1 결과가 데이터 문제 때문일까? — 6가지로 흔들어 봤다

점검 (Fama-MacBeth 9개 변수, 2011~2021)	개인 계수 (t)	외국인 계수 (t)
기본	+0.76 (3.1)	−0.23 (−1.2)
정답의 극단값을 매달 상하위 1%에서 자름(#5)	+0.60 (2.8)	−0.20 (−1.1)
퇴장 종목의 사라진 다음 달 수익률을 −30%로 채움(#4)	+0.82 (3.3)	−0.19 (−1.0)
같은 것을 −100%(완전 손실)로 채움(#4)	+0.96 (3.4)	−0.12 (−0.6)
순매수 비율이 ±20% 넘는 칸 제외(#13)	+0.78 (3.2)	−0.22 (−1.2)
t월 수익률이 정확히 0인 칸(거래정지 의심) 제외(#6)	+0.79 (3.2)	−0.22 (−1.2)
연도별 Q5−Q1 부호	11년 중 10년 +	11년 중 8년 −

결론: H1의 "반대 방향"은 극단값, 상장폐지, 거래정지, 몇몇 튀는 칸 때문이 아니다. 어떻게 흔들어도 t 2.8~3.4, 11년 중 10년 같은 방향. **데이터가 말하는 결과다.**

왜 이렇게 나왔을까? (해석 후보, 아직 결론 아님)

① **유동성 공급**(계획서에 적어 둔 H1의 반대 가능성): 외국인·기관이 급하게 팔 때 개인이 받아 주고, 그 대가로 다음 달 보상을 받는다. 개인 ↔ 외국인 −0.47, 개인 ↔ 그달 수익률 −0.29(떨어진 걸 산다)와 맞는 그림. 해외 연구(Kaniel, Saar & Titman 2008, NYSE)에서도 개인 순매수 다음 달 초과수익이 +로 나온 적이 있다.

② **단순 반전의 잔여물**: 개인이 떨어진 종목을 사고 그 종목이 반등하는 것일 수 있다. 하지만 단기 반전을 같이 넣은 Fama-MacBeth에서도 남으므로 이것만으로는 설명이 안 된다.

③ **월 단위의 한계**: 기존 한국 연구는 주로 일·주 단위였다. 월 단위로 모으면 단기 "주목 매수" 손실보다 유동성 공급 보상이 크게 보일 수 있다.

9. 최종: 어떤 변수가 왜 남았나

변수	쓸모 (XGBoost)	방향 (FM 2011~21)	결정	이유
베타	출발점 0.028	확인 못함(예상과 반대 부호)	남김	기준선(판정 면제). 단독으로는 저베타 이상현상(−).
규모	**NO (−0.005, 5/11)**	**확실 지지 (t −6.1)**	남김	기준선(판정 면제). 혼자서는 손해지만 가치와 함께일 때 가장 강한 방향 신호. 빼면 소형주 효과가 수급으로 섞일 위험.
가치	**+0.028, 9/11**	확인 못함 (전체 기간은 지지 t 2.5)	남김	기준선. 하나씩 쌓기에서 가장 큰 상승.
모멘텀	**+0.011, 7/11**	통제(방향 가설 없음)	남김	통제 규칙 통과.
단기 반전	**+0.015, 10/11**	확인 못함	남김	통제 규칙 통과. 개인 순매수와 겹치므로(−0.29) 반드시 함께 둬야 H1을 공정하게 판정.
고유변동성	**+0.011, 11/11**	확인 못함(t −1.99), 전체 기간은 확실 지지	남김	보강 묶음의 실제 기여자. 근거 논문 필요(Ang et al. 2006).
주식 발행	**NO (−0.0000, 6/11)**	확인 못함, 전체 기간은 지지	탈락 제안	방향은 맞지만 고유변동성 다음에 넣으면 새 정보가 없음. 묶음 판정은 OK였으므로 **팀이 결정**.
개인 순매수	**+0.0047, 11/11**	**반대 방향 유의 (t +3.1)**	남김	쓸모는 가장 꾸준(11년 전부). **H1은 지지되지 않음, 반대 방향**.
외국인 순매수	**+0.0017, 7/11 (약함)**	확인 못함	남김(약함)	규칙상 OK. 증가분 t 1.2로 근거 약함. **H2 확인 못함**.

> **"보강" 이름 제안:** "설명력 보강 변수". 테마(수급·뉴스)에는 직접 필요 없지만, 넣으면 평균 IC를 올리고 (+0.011, 9/11) 교수님도 "근거 논문과 함께 넣어도 됨"이라고 하신 변수라서.

10. 한계와 우리 질문 (11/16 교수님께)

1. **H1 반대 결과의 해석**: 단기 반전을 통제해도 남는 개인 순매수 + 효과를 "유동성 공급 보상"으로 해석해도 되는가? 추가로 확인해야 할 것(예: 기관 순매수, 일 단위)은?
2. **XGBoost 증가분 t**(예: 수급 +0.0043, t 2.7)를 보조 근거로 보고서에 써도 되는가?
3. **주식 발행**: 묶음 판정은 OK, 단독은 NO. 보강을 고유변동성만으로 줄여도 되는가?
4. **대형주 IC 0.023**: 보고서에 전체·대형 IC를 함께 내면 충분한가?

5. **데이터**: 2008-08~11 PBR 누락, +100% 수익률 460건의 원인(예원님 확인 요청). 2002~05년 PBR = 0이 49~64%인 이유.

한계: 고유변동성은 월 데이터 24개월 시장모형으로 만들었다(일 데이터가 아님). 시장수익률은 데이터 종목의 시총 가중 평균. Fama-MacBeth t는 일반 t(Newey-West 3개월 보정 t도 거의 같음: 개인 +3.18, 외국인 −1.15).

11. 다음: 뉴스가 오면 H3·H4는 어떻게 쌓나

네, 그대로 이어서 쌓을 수 있다. 코드가 단계 목록에 변수를 더하는 구조라서, 뉴스 변수만 만들어지면 같은 규칙과 같은 학습 방식으로 바로 돌아간다.

가설	추가할 것	판정
H3 화제 논조	4단계 "+뉴스": `topic_tone` (화제형 기사 KR-FinBert-SCP(긍정)−P(부정) 월평균) + `no_news` (그달 화제 기사 없음 = 1). 기사가 없으면 논조는 0.5(중간) + 표시 1.	쓸모: 3단계 대비 평균 IC↑ & 6/11년. 방향: FM에서 `topic_tone` 계수 + 이고 $t \geq 2$.
H4 설거지 표	모델 밖 비교표. 호재 종목(화제 기사 있고 논조가 그달 중간값보다 높음) 안에서 개인 많음 vs 적음의 다음 달 수익률 차이 − 기사 없는 종목에서의 같은 차이.	차이의 차이가 − 이고 $t \leq -2$ → 지지.

> **오늘 결과가 H4에 주는 의미:** 기사가 없는 종목에서도 "개인 많음 − 적음"이 이미 + 쪽일 가능성이 크다(H1 결과). 그래서 H4는 반드시 **기사 없는 종목과의 차이(차이의 차이)**로 봐야 한다. 호재 종목에서만 + 폭이 작아지거나 −로 뒤집히면, 그게 "호재에 개인이 몰리면 더 약하다"의 증거가 된다. 비교군을 미리 넣어 둔 설계가 여기서 빛을 본다.

부록. 재현 방법

순서	파일 (연습장/)	하는 일 → 결과
1	step1_features.py <데이터폴더>	변수·정답 만들기 → out/features.parquet, coverage_by_year.csv
2	step2_preview.py	방향 미리 보기 → 그림 A·B, preview_*.csv
3	step3_xgb_stages.py	XGBoost 누적 학습 단계별 IC(약 8분, CPU) → stage_ic*.csv
4	step4_fm_h1h2.py	Fama-MacBeth, 수급 표 → 그림 E·F·G
5	step5_plots.py · step6_bigcap.py	그림 C·C2·C3·D, 규모별 IC
6	step7_datamap.py · step8_corr.py	그림 0·H

패키지: xgboost 3.2.0(팀 requirements와 같음), pandas, numpy, matplotlib, koreanize-matplotlib. 입력 데이터는 Git에 올리지 않는다(팀 규칙). 2022년 이후 행은 step1에서 읽자마자 버린다.